Inferencia Bayesiana Causal

IBC1.2026.1

Profesor: Gustavo Landfried[1,2,3]
Ayudantes: Gerardo Toboso, Lucas Barreiro [1,2]

1. Escuela de Ciencia y Técnica. Universidad Nacional de San Martín.

2. Laboratorios de Métodos Bayesianos

3. Muttdata

Correspondencia: `glandfried@dc.uba.ar`

28 de febrero de 2026

Todas las ciencias con datos desarrollan argumentos causales para explicar y predecir el mundo. La evaluación de hipótesis causales atrae cada vez más el interés de las industrias, que necesitan medir el impacto real de sus acciones. La ventaja de los modelos causales radica en su capacidad predictiva, que se adapta naturalmente a los cambios del contexto como son las intervenciones humanas. Además sabemos que si los argumentos causales se corresponden con la realidad causal subyacente ningún modelo de inteligencia artificial, por más complejo que sea, puede mejorar su desempeño.

En este curso revisaremos los fundamentos de la evaluación de modelos causales alternativos M dado los datos D, $P(M|D)$, tanto con y sin intervenciones. Además revisaremos los métodos para hacer predicciones de las hipótesis H internas a los modelos M, $P(H|D, M)$, tanto para evaluar efectos causales out-of-sample como para predecir el impacto de acciones alternativas contrafactuales. Finalmente abordaremos el problema de tomar decisiones óptimas como un problema de inferencia en el que se revisa que ninguna de las decisiones contrafactuales alternativas mejoren el resultado de la variable objetivo.

Ante el vértigo de una IA plagada de herramientas efímeras, este curso prioriza los fundamentos inmutables. A pesar de todos los avances, desde el siglo 18 hasta ahora no se ha propuesto un nuevo sistema para razonar bajo incertidumbre. Si algún día las máquinas superan a los humanos, deberán hacer ciencia aplicando estrictamente las reglas de probabilidad para evaluar teorías causales. Para alcanzar verdades (intersubjetivas) en contextos de incertidumbre, simplemente hay que saber aplicar y preservar el principio universal de no mentir: no afirmar más de lo que se sabe, sin ocultar lo que sí se sabe. Así se obtienen las distribuciones de creencia óptima dada la información disponible, inmejorables en términos prácticos.

Al final siempre es bueno recordar que la verdadera inteligencia no es ni artificial ni humana, sino que está en todas las formas de vida que son capaces de sobrevivir en el tiempo. Especialmente las plantas que son 83 % de la biomasa, no molestan a nadie y dan vida.

Objetivos

Este curso está enfocado en la evaluación de argumentos causales alternativos mediante la (aproximación a) la aplicación estricta de las reglas de la probabilidad (enfoque bayesiano), el sistema de razonamiento en contextos de incertidumbre. El principal objetivo es revisar los métodos desarrollados en las últimas décadas para:

- **Modelos causales**. Especificar matemáticamente los argumentos causales expresados en lenguaje natural mediante métodos gráficos intuitivos
- **Flujo de inferencia**. Entender cuándo se abre y se cierra el flujo de inferencia en las estructuras causales, para separar las influencia espuria de la influencia causal.
- **Estimación de efectos causales**. Aplicar métodos de Aprendizaje Automático para identificar el efecto causal entre pares de variables a partir de datos observados sin intervenciones.
- **Predicciones contrafactuales**. Especificación de distribuciones de probabilidad conjunta entre factuales y contrafactuales, y razonamiento generativos de las consecuencias contrafactuales.
- **Toma de decisiones en el tiempo**. Seleccionar decisiones óptimas en ciclos de acción-percepción con una naturaleza oculta (simulada).

Sobre el docente

Gustavo Landfried es profesor de Inferencia Bayesiana Causal en la Escuela de Ciencia y Técnica de la Universidad Nacional de San Martín. Luego de obtener la licenciatura en Antropología Social, Gustavo se doctoró en Ciencias de la Computación por la Universidad de Buenos Aires bajo la supervisión de los directores del Laboratorio de Inteligencia Artificial Aplicada (Diego Slezak) y del Laboratorio interdisciplinarios de Cómputo de Alto Rendimiento (Esteban Mocskos). Allí se especializó en el análisis de habilidad de la industria del video juego, basado en métodos bayesianos, lo que lo llevo a desarrollar y mantener los paquetes estado-del-arte en Python, Julia y R (TrueSkill Through Time). Gustavo trabaja actualmente en la industria (Muttdata) como Data Scientist desarrollando proyectos de inferencia bayesiana e inferencia causal para grandes empresas transnacionales de América Latina. Además es cofundador y coordinador de la comunidad `bayesplurinacional.org`.

Unidades

1. Especificación y evaluación de argumentos causales. 3
1.1. Argumentos causales alternativos e incertidumbre. 3
1.2. Sorpresa: el problema de la comunicación con la realidad. 4

2. Métodos de inferencia y programación probabilística. **4**
2.1. Inferencia exacta y pasaje de mensajes. 4
2.2. Olvido: el problema de la inferencia aproximada 5

3. Predicciones causales. **5**
3.1. Flujo de inferencia y eliminación de la influencia espuria. 5
3.2. Estimandos, Do-Calculus. 6

4. El zoológico de algoritmos. **6**
4.1. Métodos tradicionales. 6
4.2. Algoritmos principales en las competencias de inferencia causal. 6

5. Tiempo. **7**
5.1. Algoritmos temporales. 7
5.2. Modelos causales generativos temporales. 7

6. Contrafactuales. **7**
6.1. Modelos con contrafactuales y equivalencia entre enfoques de inferencia causal. 7
6.2. El uso de contrafactuales para la estimación de efectos causales directos. . . . 8

7. Toma de decisiones **8**
7.1. Toma de decisiones en el tiempo: la función de costo epistémica-evolutiva. . . 8
7.2. Corrección temporal de la Teoría de Utilidad Esperada y optimización como inferencia. 8

8. Intervenciones socioeconómicas **9**
8.1. Historia general, bienes comunes e instituciones exitosas. 9
8.2. Instrumento financiero productivo 9

9. Bibliografía **9**

Todas las sub-unidades tienen entregas y al finalizar toda una unidad se realiza una evaluación basada en multiple-choice con distribución de creencias.

1. Especificación y evaluación de argumentos causales.

Sistema de razonamiento en contextos de incertidumbre, especificación gráfica de argumentos causales y evaluación de modelos causales alternativos con y sin intervenciones.

1.1. Argumentos causales alternativos e incertidumbre.

Verdad y mentira. Acuerdos intersubjetivos: máxima incertidumbre dada la información disponible. Distribución de creencias honesta entre los universos paralelos de los argumentos causales. Preservación de la creencia previa compatible con el dato y predicción como suma de universos paralelos compatibles con lo que se quiere predecir. Sistema de razonamiento en contextos de incertidumbre: las reglas de la probabilidad. Métodos gráficos de especificación matemática de argumentos causales probabilísticos: redes bayesianas. Las propiedades básicas de los modelos gráficos: estructura, independencia y factorización. Medición de incertidumbre

sobre espacio de hipótesis internas a los modelos, $P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$. La evaluación de argumentos causales alternativos en datos observados sin intervenciones, $P(\text{Modelo}|\text{Datos})$. La evidencia, $P(\text{Datos}|\text{Modelo})$, y sus transformaciones (media geométrica y logaritmo).

Entrega 1.1: Especificación y evaluación de modelos Monty Hall y Base.

Bibliografía teórica sugerida 1.1: Capítulos 2 y 3 (hasta el final de la sección 3.2) de libro de Daphne Koller (2009) *Probabilistic Graphical Models* [3].

Bibliografía práctica sugerida 1.2: Capítulo 1 y 2 del libro de McElreath (2020) *Statistical rethinking* [**?**]

1.2. Sorpresa: el problema de la comunicación con la realidad.

Los elementos fundamentales del sistema de razonamiento bajo incertidumbre (axiomas de Kolmogorov y Rényi). La estructura invariante del dato empírico. Su isomorfismo con los sistemas de comunicación con la realidad. La sorpresa como fuente de información. La equivalencia entre la media geométrica de la predicción, $P(\text{Datos}|\text{Modelo})$ y la entropía cruzada. La ventaja de los modelos causales que se corresponden con la realidad causal subyacente. La definición matemática del principio de no-mentir: máxima entropía dada información disponible. Especificación de modelos causales para contextos con datos corrompidos. Mecanismos causales adaptativos al contexto: do-operator y gates. Especificación de argumentos causales mediante factor graphs. Identificación de modelos causales con y sin intervenciones. Evaluación de procedimientos alternativos de medición.

Entrega 1.2: Especificación y evaluación de modelo Monty Hall con datos corrompidos.

Bibliografía teórica sugerida 1.2: Secciones 1.1, 2.4-6, 4.1 del libro de MacKay (2003) *Information theory, inference and learning algorithms.* [4]

Bibliografía práctica sugerida 1.2: Capítulo 3 y 10 del libro de McElreath (2020) *Statistical rethinking* [**?**]

2. Métodos de inferencia y programación probabilística.

Métodos de inferencia exacta a través de pasaje de mensajes entre los nodos de la red causal e inferencia aproximada análitica y por sorteo a través de lenguajes de programación probabilística.

2.1. Inferencia exacta y pasaje de mensajes.

Inferencia exacta. El algoritmo de eliminación de variables. Descomposición de las reglas de la probabilidad como mensajes que se envían entre sí los nodos de las redes causales: algoritmo suma-producto. El caso del modelo Monty Hall extendido. Distribuciones conjugadas. Modelo Beta-Bernoulli y sus aplicaciones en medicina y marketing. Modelo gaussianos unidimensionales y la solución exacta al modelo de estimación de habilidad. Modelo gaussianos multidimensionales: posterior y evidencia. Regresión lineal bayesiana. Selección arbitraria de hipótesis mediante máxima verosimilitud. Interpretación de los parámetros estimados bajo realidades causales conocidas. Evaluación de modelos lineales de complejidad creciente. La ausencia de overfitting mediante la aplicación estricta de las reglas de la probabilidad. Predicción basada en ensambles de modelos, $P(\text{Datos})$.

Entrega 2.1: Evaluación de modelos lineales de complejidad creciente.

Bibliografía teórica sugerida 2.1: Capítulos 9 y 10 del libro de Daphne Koller (2009) *Probabilistic Graphical Models* [3].

Bibliografía práctica sugerida 1.2: Capítulo 4 y 5 del libro de McElreath (2020) *Statistical rethinking* [**?**]

2.2. Olvido: el problema de la inferencia aproximada

Métodos analíticos de aproximación. Divergencia KL e inferencia aproximada por expectation propagation. El caso de la estimación de habilidad en la industria del video juego. Divergencia KL invertida e inferencia aproximada por variational inference. El caso de la versión bayesiana del sistema de recomendación ganador de la competencia de Netflix. El lenguaje de programación probabilística `pyro`. Métodos de aproximación por sorteo. Inferencia aproximada por Monte Carlo: metropolis-hasting, Hamiltonian Monte Carlo y Sequential Monte Carlo. Lenguajes de programación probabilística `pymc, stan, turinglang`. El caso de la evaluación de instrumentos alternativos de medición, y el p-valor bayesiano. Métodos generativos de aproximación. Computación Bayesiana Aproximada (ABC): inferencia libre de verosimilitud mediante estadísticos de resumen y métricas de distancia. Métodos actuales de estimación de la distribución conjunta mediante redes neuronales a partir de datos simulados (SBI) e inferencia eficiente.

Entrega 2.2: Evaluación de instrumentos alternativos de medición: test diagnóstico de Chagas con datos corrompidos.

Bibliografía teórica sugerida 2.1: Capítulos 11 y 12 del libro de Daphne Koller (2009) *Probabilistic Graphical Models* [3].

Bibliografía práctica sugerida 1.2: Capítulo 9 del libro de McElreath (2020) *Statistical rethinking* [**?**]

3. Predicciones causales.

Eliminación de la influencia espuria de las predicciones y los pasos de la inferencia causal: 1) especificación de la estructura causal, 2) identificación del estimando, 3) estimación del efecto causal.

3.1. Flujo de inferencia y eliminación de la influencia espuria.

Flujo de inferencia en redes causales. Apertura y cierre de flujo de inferencia en las estructuras básicas: pipe, fork y collider. Apertura y cierre del flujo de inferencia en caminos de cualquier longitud: d-separation. Eliminación de influencia espuria de las predicciones: controles backdoor. Buenos y malos controles. Controles neutrales y efectos causales heterogéneos. Uso de la regresión lineal para estimación de efectos causales no lineales. Interpretación de los coeficientes estimados. The Table 2 Fallacy. Los pasos de la inferencia causal: 1) especificación de la estructura causal, 2) identificación del estimando, 3) estimación del efecto causal. Descubrimiento de estructuras causales compatibles con las distribuciones de probabilidad conjunta estimadas de los datos.

Entrega 3.1 Predicciones causales en diversas realidades causales subyacentes.

3.2. Estimandos, Do-Calculus.

El estimando del efecto causal general: adjustment formula y propensity score. La característica fundamental de los experimentos aleatorizados: independencia entre el tratamiento y sus resultados potenciales contrafactuales. La analogía "ignorabilidad condicional" como criterio para seleccionar variables de control en el enfoque previo de inferencia causal basado en resultados potenciales contrafactuales. Estimando del efectos causales bajo ignorabilidad condicional y consistencia determinista. Las 3 reglas del Do-calculus: Regla 1, Ignorar una observación; Regla 2, Intervención como observación; Regla 3. Ignorar una intervención. Estimando alternativo en casos de que haya controles ocultos: frontdoor formula. Estimando alternativo cuando fallan los experimentos aleatorios: instrumental variables.

Entrega 3.2. Estimación de efectos causales: general, frontdoor e instrumentales.

4. El zoológico de algoritmos.

De las primeras estrategias hasta los modelos de aprendizaje supervisado de última generación con probada con capacidad para la estimación de efectos causales heterogéneos en contextos de alta dimensionalidad.

4.1. Métodos tradicionales.

Métodos tradicionales de estimación de efectos. Comparación de unidades tratadas y de control con características similares: Matching. El uso del Propensity Score como medida de similaridad. Re-ponderación de la muestra a través del Propensity Score: Inverse Probability Weighting (IPW). Limitaciones de los métodos tradicionales ante la alta dimensionalidad. La solución del Causal Machine Learning (CausalML): algoritmos de alta capacidad predictiva para estimar efectos causales heterogéneos (CATE). El ecosistema de inferencia causal en Python: integración de `DoWhy`, `EconML` y `CausalML`. El concepto de Meta-Learners: estrategias para descomponer la estimación del efecto causal condicional (CATE) en problemas de predicción supervisada estándar. S-Learner y T-Learner, ventajas y desventajas. El impacto de la falta de "positividad" en las predicciones causales: el caso de la industria de los préstamos personales.

Entrega 4.1. Predicccciones causales bajo diferentes grados de positividad.

4.2. Algoritmos principales en las competencias de inferencia causal.

Fundamentos y aplicación de Doubly Robust Learner Las competencias de inferencia causal de la Atlantic Causal Inference Conference. El problema de la regularización en la estimación del efecto causal. Estrategia de estimación bajo modelos parcialmente lineales: ortogonalización. Fundamentos y aplicación de Doubly Machine Learning: regularización en los nuisance models y aislamiento del efecto causal. Algoritmos no lineales basados en ensables de árboles. De los Random Forest a los Causal Forest. De los Bayesian Additive Random Trees al Bayesian Causal Forest. El problema de los intervalos de confianza estimados en las competencias de datos y posibles soluciones. Algoritmos híbridos.

Entrega 4.2. Competencia de inferencia causal ACIC 2022.

5. Tiempo.

Algoritmos especializados para la estimación de efectos causales en series temporales. Modelos causales generativos temporales, especificación, inferencia y evaluación.

5.1. Algoritmos temporales.

La ventaja de los datos longitudinales: efectos fijos invariantes en el tiempo. Difference-in-Differences (DiD) clásico. El problema de DiD con efectos heterogéneos. DiD con múltiples períodos y timing escalonado (staggered adoption). Nuevos estimadores robustos: Callaway-Sant'Anna, Sun-Abraham, Doubly Robust DiD. El problema de la ausencia de unidades de control comparables. Construcción de grupos de control sintéticos mediante combinación ponderada de unidades no tratadas. Combinación de pesos sintéticos con estructura DiD permitiendo timing escalonado y tendencias heterogéneas: Synthetic Difference-in-Differences. Generalización de controles sintéticos para múltiples unidades tratadas simultáneamente mediante imputación de datos faltantes: Matrix Completion.

Entrega 5.1. Estimación de efectos causales temporales comparando diferentes métodos.

5.2. Modelos causales generativos temporales.

Especificación de modelos causales temporales y su despliegue (unrolling). Estimación de habilidad en la industria del video juego y los deportes. Flujo de inferencia en modelos generativos de historia completa: forward y backward propagation. Mensajes indefinidos y convergencia por Loopy Belief Propagation. El algoritmo forward-backward (smoothing): estimación de habilidad en el tiempo. Predicciones temporales y predicciones leave-one-out: costos. Estimación de habilidad en la historia del tenis. La interpretación del pago que ofrecen las casas de apuestas. Juegos de apuestas simplificado: la moneda honesta. Propiedades de los juegos de apuestas. La ventaja de la diversificación individual (entropía negativa).

Entrega 5.2.. Especificación de un modelo causal generativo temporal de apuestas. Simulación y análisis de impacto de la cooperación y el ahorro individual.

6. Contrafactuales.

Especificación de modelos con contrafactuales, equivalencia entre enfoques de inferencia causal, y descomposición de efectos totales en efectos naturales directo e indirecto mediante mediation formula.

6.1. Modelos con contrafactuales y equivalencia entre enfoques de inferencia causal.

Los niveles del razonamiento causal. La especificación de modelos causales con contrafactuales: Twin Networks. Predicción de contrafactuales usando la información factual: Monty Hall. Revisando la equivalencia de los dos enfoques de inferencia causal: Potential Outcomes y Structural Causal Models. Análisis de cumplimiento de ignorabilidad mediante Twin Networks: ejemplos. Restricciones específicas de los Structural Causal Models: una variables exógenas por cada variable endógena y determinismo de las variables endógenas. Ruptura de

la equivalencia Ignorabilidad-Backdoor en modelos generativos causales: el contraejemplo paradigmático. Generalización del enfoque de inferencia causal Backdoor a modelos generativos causales generales.

Entrega 6.1. Predecir valores contrafactuales usando información factual.

6.2. El uso de contrafactuales para la estimación de efectos causales directos.

Efectos causales Totales vs Directos e Indirectos. Conditional Direct Effect: una intervención contraindicada. Descomposición del efecto total: Natural Direct Effect, el impacto que produce el tratamiento bajo un mediador sin tratamiento; Natural Indirect Effect, el impacto que produce el cambio del medidor bajo tratamiento. El debate Burks-Hammel: medición de la discriminación de género en la admisión universitaria. Identificabilidad de efectos naturales: eliminación de la influencia espuria entre el mediador y el resultado. Mediation formula: estimandos NDE y NIE a partir de datos observacionales y modelos estructurales. Estimación de NDE y NIE en datos observados sin intervenciones.

Entrega 6.2. Evaluación de discriminación en datos simulados

7. Toma de decisiones

El isomorfismo probabilidad-evolución, las consecuencias de la naturaleza multiplicativa de la selección de variantes, y la corrección temporal de la teoría de utilidad esperada.

7.1. Toma de decisiones en el tiempo: la función de costo epistémica-evolutiva.

La teoría de utilidad esperada de Von Neumann. La crítica de John L. Kelly a Von Neumann. Juegos de apuestas. La equivalencia estructural entre los juegos de apuestas, la evaluación de hipótesis en probabilidad y la selección de formas de vida en evolución. La ventaja de la diversificación individual (entropía negativa). Las propiedades emergentes de las formas de la materia y la ventaja de la reducción de fluctuaciones por cooperación. La falacia del dilema del prisionero y la tragedia de los comunes. La ventaja de la especialización cooperativa. El criterio Kelly: cooperar con uno mismo. Fractional Kelly.

Entrega 7.1: Estimación de habilidad y apuestas de tenis.

7.2. Corrección temporal de la Teoría de Utilidad Esperada y optimización como inferencia.

Sistemas de interacción con la realidad: acción-percepción. Active learning. Predicción por máxima incertidumbre y selección de acciones por mínima incertidumbre. La corrección ergódica (temporal) de la teoría de utilidad esperada. Decisión factual óptima como ausencia de alternativas contrafactuales superiores. Optimización como inferencia. Los diagramas de influencia basados en contrafactuales: el juego de apuestas y solución a la especialización (individual y fondo común de 2 personas). Políticas determinísticas y experimentos aleatorios por goteo. El caso de la industria de los préstamos personales: asignación determinista de los créditos. Estrategias para realizar micro experimentos aleatorios, minimizando la producción

y recolección de datos: el valor de la información.

Entrega 7.2: Micro experimentos y evaluación de política en la industria de los préstamos personales.

8. Intervenciones socioeconómicas

Historia del giro colonial-moderno, gobernanza de los bienes comunes, análisis de casos actuales, diseño de instrumento financiero-productivo en todos sus niveles (ahorro, ordenamiento territorial, servicios básicos, acceso a la vivienda, reproducción del ciclo).

8.1. Historia general, bienes comunes e instituciones exitosas.

Los límites de la estimación de efectos causales entre pares de variables. El caso de la violencia de genero y la asignación aleatoria de subsidio para la vivienda. El desarrollo de la cultura y la agricultura. Los 6 centros de innovación de la humanidad. El giro colonial-moderno: pandemia fedual, plata americana, y tecnología china. La era de los genocidios y la pérdida de diversidad cultural. La profundización de la crisis ecológica actual y la incapacidad de la ciencia metropolitana moderna para resolverlo. Las característica de los sistemas institucionales exitosos en la administración de los bienes comunes. Egipto, distribución de la tierra, productividad agrícola, densidad poblacional y dinámica demográfica. Argentina, distribución de la tierra, productividad agrícola, densidad poblacional y dinámica demográfica.

Entrega 8.1: Reporte: análisis sobre los datos de Argentina y Egipto; estimaciones, conclusiones y propuestas de acción.

8.2. Instrumento financiero productivo

Sistemas financieros-productivos en la Argentina actual: tasa de interés, riesgo y liquidez. Fuente de valor real: el agua, la tierra y la vida. Instrumento financiero de ahorro-productivo pool de siembra basado en agricultura intensiva y urbanización de la ruralidad. Los tres actores del sistema: ahorristas, habitantes y administración. Ahorro basado en pooles de compra de tierra rural (bloques de más de 100 ha), y tasa de interés acorde al valor del alquiler rural. Ordenamiento general de la tierra: caminos, vivienda, agricultura de quintas, y espacios comunes. Ordenamiento específico de los sectores y tamaño mínimo de las zona rural (quintas de 2000m2) y de las viviendas (250m2). Desarrollo de servicios básicos: agua, cloaca, cimientos y área común. Los requisitos de los habitantes para adquirir la propiedad: costo total y tiempos para la cancelación de la deuda. El ciclo completo para la reproducción del proceso. Capacidades y velocidad estimada de crecimiento potencial.

Entrega 8.2: Redacción del reporte técnico y el resumen ejecutivo del instrumento financiero productivo.

9. Bibliografía

Fundamentos

[1] Bishop, C.M. *Pattern Recognition and Machine Learning*. Springer (2006)

[2] Jaynes, E.T. *Probability Theory: The Logic of Science*. Cambridge University Press (2003)

[3] Koller, D., Friedman, N. *Probabilistic Graphical Models: Principles and Techniques*. MIT press (2009)

[4] MacKay, D.J. *Information Theory, Inference and Learning Algorithms*. Cambridge University Press (2003)

[5] Pearl, J. *Causality*. Cambridge University Press (2009)

[6] Pearl, J., Mackenzie, D. *The Book of Why*. Basic books (2018)

[7] Peters, J., Janzing, D., Schölkopf, B. *Elements of Causal Inference: Foundations and Learning Algorithms*. The MIT Press (2017)

[8] Winn, J., Bishop, C.M., Diethe, T., Zaykov, Y. *Model-Based Machine Learning* (2023)

Práctica

[9] Facure, M. *Causal Inference in Python: Applying Causal Inference in the Tech Industry*. O'Reilly Media, Inc. (2023), see also *Causal Inference for The Brave and True* (Notebooks)

[10] McElreath, R. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan.* CRC Press (2020)

[11] Molak, A. *Causal Inference and Discovery in Python: Unlock the secrets of modern causal machine learning with DoWhy, EconML, PyTorch and more*. Packt Publishing Ltd (2023)

[12] Neal, B. *Introduction to Causal Inference from a Machine Learning Perspective. (draft)*. Course lecture notes (2020)

Lenguajes de programación probabilística

[13] Bingham, E., Chen, J.P., Jankowiak, M., Obermeyer, F., Pradhan, N., Karaletsos, T., Singh, R., Szerlip, P., Horsfall, P., Goodman, N.D. *Pyro: Deep universal probabilistic programming*. Journal of Machine Learning Research 20(28), 1–6 (2019), `https://pyro.ai/`

[14] Fjelde, T.E., Xu, K., Widmann, D., Tarek, M., Pfiffer, C., Trapp, M., Axen, S.D., Sun, X., Hauru, M., Yong, P., et al. *Turing.jl: a general-purpose probabilistic programming language*. ACM Transactions on Probabilistic Machine Learning (2025), `https://turinglang.org/`

[15] Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C.J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C.C., Martin, O.A., et al. *PyMC: a modern, and comprehensive probabilistic programming framework in Python*. PeerJ Computer Science 9, e1516 (2023), `https://www.pymc.io`

[16] Carpenter, B., Gelman, A., Hoffman, M.D., Lee, D., Goodrich, B., Betancourt, M., Brubaker, M., Guo, J., Li, P., Riddell, A. *Stan: A probabilistic programming language*. Journal of Statistical Software 76, 1–32 (2017), `https://mc-stan.org/`

Otros textos claves

[17] Bishop, C.M., Bishop, H. *Deep Learning: Foundations and Concepts*. Springer Nature (2023)

[18] Frank, S.A. The common patterns of nature. Journal of evolutionary biology 22(8), 1563–1585 (2009)

[19] Halpern, J.Y. Reasoning about uncertainty. MIT press, 2nd edn. (2017)

[20] Levine, S. Reinforcement learning and control as probabilistic inference: Tutorial and review. arXiv preprint arXiv:1805.00909 (2018), `https://arxiv.org/pdf/1805.00909.pdf`

[21] Parr, T., Pezzulo, G., Friston, K.J. Active inference: the free energy principle in mind, brain, and behavior. MIT Press (2022)

[22] Popper, K. The logic of scientific discovery (Logik der Forschung, 1934). Routledge (1968)

[23] Poundstone, W. Fortune's formula: The untold story of the scientific betting system that beat the casinos and Wall Street. Hill and Wang (2010)

[24] Rényi, A. On a new axiomatic theory of probability. Acta Mathematica Hungarica 6(3-4), 285–335 (1955)

[25] Samaja, J. Epistemología y metodología: elementos para una teoría de la investigación científica. EUDEBA (1999)