Práctica 1 - Entrega 1
Argumentos causales alternativos e incertidumbre.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
1er cuatrimestre 2026
UNSAM - Bayes Plurinacional

Índice

1. Modelo Base vs Modelo Monty Hall **2**
1.1. Definir la distribución de creencia conjunta como producto de las distribuciones condicionales del modelo . . . 3
1.2. Simular datos con el modelo Monty Hall . . . 5
1.3. Calcular la predicción a priori que hace cada uno de los modelos sobre la totalidad de la base de datos simulada . . . 6
1.4. Diferencia de predicciones a priori sobre los datos en órdenes de magnitud. . . . 7
1.5. Calcular la predicción típica que hace el modelo de los episodios. . . . 8
1.6. Calcular la predicción de los datos con la contribución de todos los modelos. . . . 10
1.7. Calcular y graficar el posterior de los modelos sobre los datos simulados . . . 11

1. Modelo Base vs Modelo Monty Hall

Los datos no hablan por sí solos. Lo que hacemos en Bayes casi siempre es lo mismo: inventamos (con cuidado) una historia del mundo que podría haber generado los datos, y después vemos cuál historia se banca mejor lo que observamos.

En esta práctica vas a comparar dos historias causales probabilísticas para el mismo juego:

En la figura 1 se ve la especificación gráfica del modelo "Monty Hall" (derecha) y el modelo "Base" (izquierda), usando notación de redes bayesianas. Abajo de cada uno aparece una distribución *a posteriori* sobre la posición del regalo luego de haber reservado la caja 1 y luego de que nos hayan mostrado que en la caja 2 no estaba el regalo: $P(r|s = 2, c = 1)$.

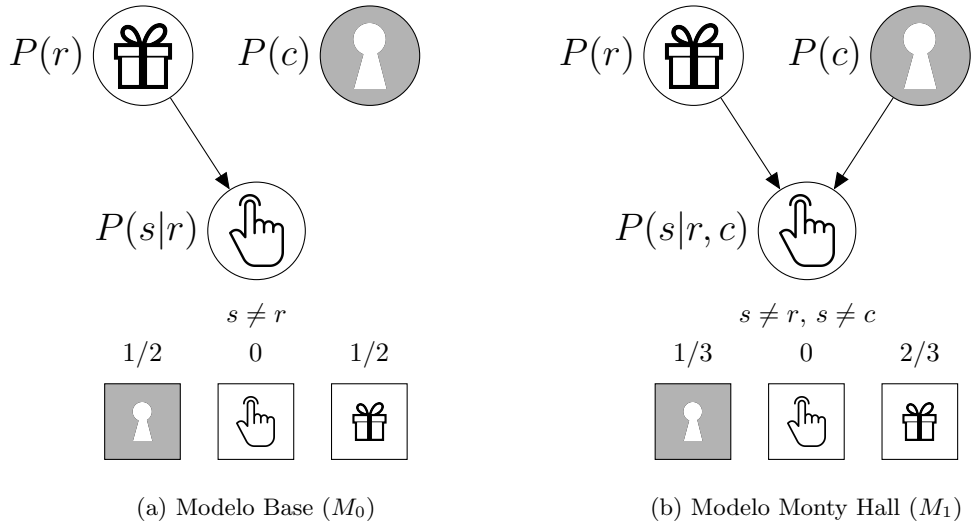

(a) Modelo Base (M_0)

(b) Modelo Monty Hall (M_1)

Figura 1: Modelos causales probabilísticos alternativos representados mediante la notación de redes bayesianas causales.

Las redes bayesianas son un método gráfico de especificación matemática de la distribución de probabilidad conjunta entre las variables (nodos de la red) mediante la definición de una distribución de probabilidad condicional por cada una de las variables, donde las flechas representan las dependencias condicionales entre variables. Una misma distribución conjunta se puede descomponer de muchas formas alternativas. Una red bayesiana es causal solo cuando la descomposición se corresponde con la semántica causal, es decir, las distribuciones de probabilidad condicional representan mecanismos causales probabilísticos entre causas y efectos. Los modelos Base y Monty Hall son ejemplos de redes bayesianas causales.

Las redes bayesianas causales encapsulan todas las hipótesis de investigación que se utilizan para interpretar los datos y sacar conclusiones sobre las hipótesis ocultas. La única restricción que supone el modelo Base (izquierda) es que la pista s no puede señalar la caja en la que se encuentra el regalo: $s \neq r$. El modelo Monty Hall (derecha) incluye esa restricción y agrega una más: la pista s tampoco puede señalar la caja que ya reservaste: $s \neq c$.

Ahora viene la parte interesante: estos modelos también son hipótesis. Y si son hipótesis, se pueden comparar. El objetivo de esta guía es actualizar nuestras creencias sobre modelos alternativos luego de observar un conjunto de datos: $P(\text{Modelo}|\text{Datos})$.

$$P(\text{Modelo}|\text{Datos}) = \frac{P(\text{Datos}|\text{Modelo})P(\text{Modelo})}{P(\text{Datos})}$$

Para ello deberemos calcular:

- La predicción que hace el modelo sobre los datos: $P(\text{Datos}|\text{Modelo})$
- La predicción de los datos realizada con la contribución de todos los modelos: $P(\text{Datos})$

- La creencia previa "honesta" sobre los modelos: $P(\text{Modelo})$

Checklist:

- Tenés claro qué significa (en palabras) $P(\text{Datos}|\text{Modelo})$: "si el mundo fuera este modelo, ¿qué tan esperables son estos datos?".
- Te queda claro que $P(\text{Datos})$ es una mezcla/ensamble de predicciones, ponderada por tu prior de modelos.
- La fórmula del posterior de modelos te suena a "prior $\times$ evidencia, normalizado".

Qué vamos a lograr en esta parte:

- Escribir dos modelos (Base M_0 y Monty Hall M_1) como redes bayesianas causales.
- Simular datos suponiendo que la "realidad" sigue M_1.
- Calcular, episodio por episodio, qué tan bien predice cada modelo los datos (la evidencia).
- Ver cómo cambia tu creencia sobre los modelos: $P(\text{Modelo}|\text{Datos})$.

1.1. Definir la distribución de creencia conjunta como producto de las distribuciones condicionales del modelo

La figura 1 no es solo un dibujo ilustrativo: nos está diciendo exactamente cómo factorizar la distribución conjunta. Acá la idea práctica es simple: vamos a construir $P(r, c, s|M)$ a partir de piezas más chicas (priors y condicionales).

Las distribuciones conjuntas de los modelos, $P(r, c, s|M)$, se pueden reconstruir como el producto de las distribuciones de sus mecanismos causales probabilísticos.

$$\underbrace{P(r,c,s|M_0)}_{\substack{\text{Prior conjunto}\\ \text{hipótesis en } M_0}} = \underbrace{P(r|M_0)P(c|M_0)P(s|r,M_0)}_{\substack{\text{Relaciones causales probabilísticas}\\ \text{propuestas por el modelo } M_0}} \quad , \quad \underbrace{P(r,c,s|M_1)}_{\substack{\text{Prior conjunto}\\ \text{hipótesis en } M_1}} = \underbrace{P(r|M_1)P(c|M_1)P(s|r,c,M_1)}_{\substack{\text{Relaciones causales probabilísticas}\\ \text{propuestas por el modelo } M_1}}$$

Ambos modelos suponen que r y c son variables independientes. Maximizando incertidumbre entre las 3 opciones obtenemos distribuciones condicionales a priori sobre r y c iguales en ambos modelos.

$$P(r|M) = P(r) = \begin{array}{c|c|c} r=0 & r=1 & r=2 \\ \hline 1/3 & 1/3 & 1/3 \end{array} \qquad P(c|M) = P(c) = \begin{array}{c|c|c} c=0 & c=1 & c=2 \\ \hline 1/3 & 1/3 & 1/3 \end{array}$$

La única diferencia entre los modelos aparece en la distribución condicional sobre la pista. El modelo Base M_0 supone que s depende únicamente de r (con la restricción $s \neq r$), mientras que el modelo Monty Hall M_1 considera que s depende tanto de r como de c (con las restricciones $s \neq r$ y $s \neq c$). Maximizando incertidumbre entre las opciones disponibles obtenemos la siguiente distribución condicional para el modelo Base (que solo depende del regalo r).

$$P(s|r, M_0) = \begin{array}{c|c|c|c} & s=0 & s=1 & s=2 \\ \hline r=0 & 0 & 1/2 & 1/2 \\ \hline r=1 & 1/2 & 0 & 1/2 \\ \hline r=2 & 1/2 & 1/2 & 0 \end{array}$$

Notar que hay una distribución de probabilidad por cada uno de los condicionales (cada regalo), lo que implica que (los renglones) tiene que integrar 1.

En el modelo Monty Hall el condicional depende de dos variables, el regalo r y la caja elegida c. Para simplificar, mostraremos los valores cuando $c = 1$.

$P(s|r, c = 1, M_1) =$

$(c = 0)$	$s = 0$	$s = 1$	$s = 2$
$r = 0$	0	1/2	1/2
$r = 1$	0	0	1
$r = 2$	0	1	0

Nuevamente, notar que cada renglón suma 1 pues cada condicional representa una distribución de probabilidad distinta.

Ejercicio: especificar el modelo como producto de piezas

Objetivo. Reconstruir la distribución conjunta $P(r, c, s \mid M)$ como producto de mecanismos (priors y condicionales) coherentes con cada grafo.

Guía (pasos).

1. Definí el espacio de hipótesis $\mathcal{H} = \{0, 1, 2\}$ para las tres cajas.
2. Especificá los priors $P(r)$ y $P(c)$ (uniformes si no asumís preferencias previas).
3. Implementá el mecanismo de pista para M_0: $P(s \mid r, M_0)$ con la restricción $s \neq r$.
4. Implementá el mecanismo de pista para M_1: $P(s \mid r, c, M_1)$ con las restricciones $s \neq r$ y $s \neq c$.
5. Definí la conjunta del modelo como el producto: $P(r, c, s \mid M) = P(r \mid M)P(c \mid M)P(s \mid r, c, M)$ (en M_0 el condicional no depende de c).

Checkeos rápidos.

- En las tablas condicionales, cada fila suma 1 (cada fila es una distribución distinta).
- En M_0, la única casilla prohibida para la pista es $s = r$.
- En M_1, además de $s \neq r$, también debe cumplirse $s \neq c$ (esa es la diferencia clave con M_0).

Errores comunes:

- **Síntoma:** te da un posterior raro o no te coinciden las tablas/condicionales. **Causa probable:** roles mezclados (c es tu elección, s es la pista del presentador, r es la ubicación del regalo). **Chequeo/Arreglo:** revisá nombres, orden de argumentos y que estés condicionando en las variables correctas.
- **Síntoma:** aparecen probabilidades negativas, mayores que 1, o se rompe la normalización más adelante. **Causa probable:** filas que no suman 1 en $P(s \mid \cdot)$. **Chequeo/Arreglo:** chequeá programáticamente que cada fila de la CPT sume 1 (y que las entradas prohibidas sean 0).
- **Síntoma:** M_1 termina comportándose casi igual que M_0. **Causa probable:** te olvidaste la restricción $s \neq c$ en M_1. **Chequeo/Arreglo:** verificá en la definición/simulación que nunca ocurra $s = c$ cuando estás usando M_1.

1.2. Simular datos con el modelo Monty Hall

Antes de evaluar los modelos necesitamos un conjunto de datos que provengan de la realidad causal subyacente. Podríamos buscar los datos reales del programa de televisión Monty Hall y revisar si efectivamente el modelo Monty Hall propuesto es mejor que el modelo Base. Aquí vamos a suponer que nuestro modelo Monty Hall representa perfectamente la realidad causal subyacente y vamos a generar los datos a partir de él.

Las redes bayesianas causales son siempre modelos generativos a partir de los cuales se pueden simular datos. *Ancestral sampling* es el proceso que imita la generación de datos en el mundo real siguiendo el orden causal del grafo. Primero se muestrean los valores de los nodos raíz, las variables que no dependen de ninguna otra. Y luego se van muestreando las variables para las cuales ya tienen definidas el valor de todas sus causas. Cuando todos los nodos tengan un valor, se obtiene una única muestra completa y consistente con las relaciones causales y probabilísticas definidas por la red.

Generar un conjunto de datos con $T = 16$ episodios.

$$\text{Datos} = \{(c_0, s_0, r_0), \ldots, (c_{T-1}, s_{T-1}, r_{T-1})\}$$

Ejercicio: simular datos

Objetivo. Generar un dataset simulado de $T = 16$ episodios asumiendo que el mundo sigue el modelo Monty Hall (M_1).

Guía (pasos).

1. Elegí una semilla (*seed*) para reproducibilidad.
2. Para cada episodio t, muestreá primero las variables raíz (por ejemplo r_t y c_t) desde sus priors.
3. Dado (r_t, c_t), muestreá la pista s_t usando el mecanismo $P(s_t \mid r_t, c_t, M_1)$ (mismo condicional que definiste arriba).
4. Guardá el episodio como el triple (c_t, s_t, r_t) y repetí hasta completar T episodios.

Checkeos rápidos.

- Cada episodio es un triple (c_t, s_t, r_t) y el dataset tiene forma $T \times 3$.
- En M_1 nunca debería aparecer un caso con $s_t = r_t$ ni con $s_t = c_t$.
- Si corrés dos veces con la misma semilla, obtenés exactamente el mismo dataset.

1.3. Calcular la predicción a priori que hace cada uno de los modelos sobre la totalidad de la base de datos simulada

Ahora sí, podemos calcular la predicción del conjunto de datos que hace cada uno de los modelos con la contribución de todas sus hipótesis internas.

$$P(\text{Datos} = \{\underbrace{(c_0, s_0, r_0)}_{\substack{\text{Primer}\\ \text{episodio}}}, \underbrace{(c_1, s_1, r_1)}_{\substack{\text{Segundo}\\ \text{episodio}}}, \ldots \underbrace{(c_{T-1}, s_{T-1}, r_{T-1})}_{\substack{\text{T-ésimo}\\ \text{episodio}}}\}|\text{Modelo})$$

Los modelos causales expresados en la figura 1 proponen relaciones causales probabilísticas entre las variables al interior de un episodio. En principio, estos modelos sólo están definidos para un único episodio. Para extenderlos a T episodios vamos a considerar que contamos con T repeticiones de esa misma estructura causal. Las repeticiones se especifican gráficamente mediante el uso de "placas".

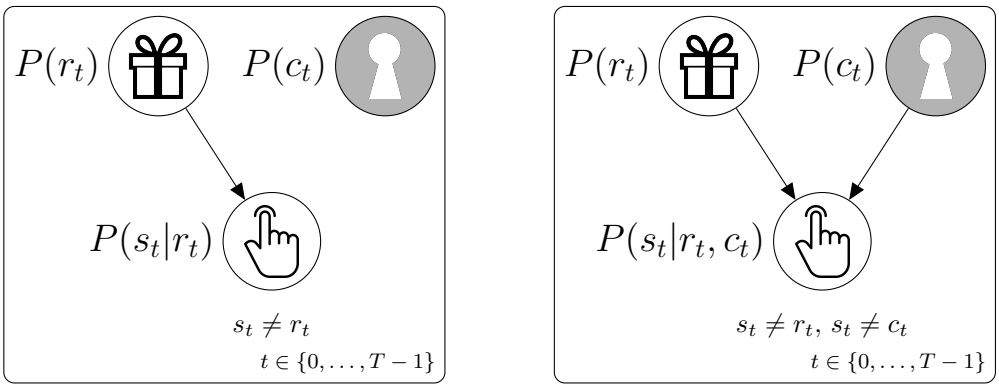

(a) Modelo Base (M_0)

(b) Modelo Monty Hall (M_1)

Figura 2: Extensión de los modelos causales alternativos a T episodios mediante la notación de "placas". El subíndice t representa las repeticiones.

Dado que entre episodios no hay flechas que vinculen entre sí las estructuras causales, lo que ocurra en un episodio no influye en lo que ocurra en otro (los episodios son independientes entre sí). Esto permite descomponer la predicción sobre el conjunto de datos sobre todos los episodios como el producto de las predicciones que lo modelos hacen al interior de cada episodio.

$$P(\text{Datos}|\text{Modelo}) = \prod_{t \in \{0,\ldots,T-1\}} P(c_t|\text{Modelo}) P(s_t|c_t, \text{Modelo}) P(r_t|s_t, c_t, \text{Modelo})$$

Ejercicio: evidencia por modelo

Objetivo. Calcular la evidencia $P(\text{Datos} \mid M)$ para M_0 y M_1, y además guardar una secuencia acumulada $P(\text{Datos}_{0:t} \mid M)$ para graficar.

Guía (pasos).

1. Implementá una función de evidencia por episodio: $P(c_t, s_t, r_t \mid M) = P(c_t \mid M)\, P(s_t \mid c_t, M)\, P(r_t \mid s_t, c_t, M)$.
2. Para cada modelo $M \in \{M_0, M_1\}$, recorré los T episodios y multiplicá las evidencias por episodio.
3. En el mismo loop, guardá el producto parcial luego de cada episodio (eso te da la curva acumulada).

Checkeos rápidos.

- La evidencia de un episodio está entre 0 y 1.
- La evidencia total suele ser muy chica (producto de muchos números menores que 1): no es un error.
- Si permutás el orden de episodios, $P(\text{Datos} \mid M)$ no debería cambiar (independencia).

1.4. Diferencia de predicciones a priori sobre los datos en órdenes de magnitud.

Ahora que generamos una predicción a priori sobre los datos generados por los modelos, podemos comparar que tan bien se ajustan estas predicciones a la realidad.ºbservada. En estos casos, para comparar el desempeño de los modelos lo que hacemos es comparar modelos de a pares.

$$\frac{P(M_i|\text{Datos})}{P(M_j|\text{Datos})} = \frac{P(\text{Datos}|M_i)P(M_i)}{P(\text{Datos}|M_j)P(M_j)} \overset{*}{=} \underbrace{\frac{P(\text{Datos}|M_i)}{P(\text{Datos}|M_j)}}_{\text{Bayes factor}} \tag{1}$$

Al dividir el valor a posteriori de los dos modelos alternativos i y j se cancela el denominador constante teorema de Bayes, $P(\text{Datos})$. Esa es la primera transformación que hacemos. Además, en el caso de que tengamos un prior uniforme entre modelos, $P(M_i) \overset{*}{=} P(M_j)$, también se cancelan los priors y la comparación del posterior de los modelos se reduce a la comparación de sus predicciones, $P(\text{Datos}|M)$. Este cociente entre predicciones de los modelos se conoce como *Bayes factor*.

Sin embargo, las predicciones sobre conjuntos de datos grandes conviene expresarlas en escala logarítmica. Además llevar la comparación a dicha escala tiene la ventaja adicional de hacer que el cociente sea simétrico.

$$\log_{10} \underbrace{\frac{P(\text{Datos}|M_i)}{P(\text{Datos}|M_j)}}_{\text{Bayes factor}} = \underbrace{\log_{10} P(\text{Datos}|M_i) - \log_{10} P(\text{Datos}|M_j)}_{\text{Diferencia predictiva en órdenes de magnitud}} \tag{2}$$

Para interpretar el significado del exponente del Bayes factor (2) es importante recordar que la verosimilitud de los modelos $P(\text{Datos}|M)$ funciona como filtro de la creencia previa. En base 10, una diferencia de un orden de magnitud significa que uno de los modelos preservó 10 veces más creencia que el otro, dos ordenes de magnitud significa que un modelos preservó 100 veces más creencia que el otro, y así sucesivamente. Aunque estos números parezcan extraordinarios, cuatro órdenes de magnitud se considera en el límite de una diferencia no concluyente. Cuando las bases de datos crecen, la diferencia en órdenes de magnitud continúan creciendo, por lo que es normal ver diferencia de 10000, pero en órdenes de magnitud! En esos casos, para ganar intuición es útil calcular la predicción "típica" (que veremos en la próxima sección).

Ejercicio: Bayes factor en escala logarítmica

Objetivo. Comparar el desempeño predictivo de los modelos Base (M_0) y Monty Hall (M_1) usando el Bayes factor en escala logarítmica.

Guía (pasos).

1. Calculá $\log_{10} P(\text{Datos} \mid M_0)$ y $\log_{10} P(\text{Datos} \mid M_1)$.
2. Para mantener las cosas fáciles supongamos priors uniformes entre modelos, en base a eso aplicá:
$$\log_{10} \text{BF}_{0,1} = \log_{10} P(\text{Datos} \mid M_0) - \log_{10} P(\text{Datos} \mid M_1).$$
3. Interpretá el resultado como una diferencia en órdenes de magnitud (base 10) a favor de M_0 frente a M_1.

Checkeos rápidos.

- Simetría: $\log_{10} \text{BF}_{0,1} = -\log_{10} \text{BF}_{1,0}$.
- Si ambos modelos predicen igual de bien, la diferencia debería quedar cerca de 0.
- Si uno de los modelos da un log-verosimilitud muchísimo menor (más negativo), el Bayes factor lo penaliza fuertemente.

1.5. Calcular la predicción típica que hace el modelo de los episodios.

Dado que la predicción sobre un conjunto de datos se descompone como el producto de las predicciones, la predicción típica es su media geométrica, la raiz N-ésima de la predicción sobre todo el conjunto de datos (donde N es el tamaño del conjunto de datos $N = |\text{Datos}|$).

$$\text{Predicción típica} := \underbrace{P(\text{Datos} = \{d_1, d_2, \ldots, d_N\}|M)^{1/N}}_{\text{Media geométrica}} \tag{3}$$

Decimos que es típica justamente porque al reemplazar cada una de las predicciones individuales que componen en la secuencia de predicciones por el valor de la media geometrica volvemos a obtener exactamente el valor de la predicción sobre todo el conjunto de datos.

$$\begin{aligned} P(\text{Datos} = \{d_1, d_2, \ldots, d_N\}|M) &= P(d_1|M)P(d_2|d_1, M)\ldots \\ &= \prod_{i\in\{1,\ldots,N\}} \text{Predicción típica} = \text{Predicción típica}^N \end{aligned} \tag{4}$$

Para calcular la media geométrica vamos a enfrentar el mismo problema de representación computacional que señalamos respecto de las predicciones sobre conjuntos de datos grandes. Por eso, para calcularla hay que trabajar con el exponente de la predicción (es decir, la escala logarítmica). La forma más sencilla es ir guardando la suma de los exponentes de las predicciones individuales,

luego obtener el exponente promedio, y finalmente transformar ese exponente en número.

$$\begin{aligned}\text{Predicción típica} &= 10^{\overbrace{\log_{10}(P(d_1|M)P(d_2|d_1,M)\dots)^{1/N}}^{\text{Exponente de la predicción típica}}} \\ &= 10^{\frac{1}{N}\left(\log_{10} P(d_1|M)+\log_{10} P(d_2|d_1,M)+\dots\right)}\end{aligned} \tag{5}$$

Este número representa la predicción típica, una probabilidad entre 0 y 1. Sirve para "humanizar" evidencias del estilo 10^{-68} sin perder la interpretación multiplicativa.

Ejercicio: calcular la predicción típica (media geométrica) en escala logarítmica

Objetivo. Calcular la predicción típica (media geométrica) que realizan los modelos Base (M_0) y Monty Hall (M_1) en escala logarítmica, interpretada como la probabilidad promedio que cada modelo asigna a una observación elemental de los datos.

Guía (pasos).

1. Recordá que la probabilidad de los datos bajo un modelo se factoriza como un producto de probabilidades elementales. En este modelo, cada episodio contiene tres observaciones: la elección del participante, la acción del presentador y la ubicación del premio.
2. Definí N como la cantidad total de observaciones elementales explicadas por el modelo. Si el dataset contiene T episodios y cada episodio tiene 3 observaciones, entonces: $N = 3T$.
3. Reutilizá el valor de $\log_{10} P(\text{Datos} \mid M)$ calculado en el ejercicio anterior.
4. Calculá el exponente promedio: $\frac{1}{N}\log_{10} P(\text{Datos} \mid M)$.
5. Transformá este valor a probabilidad típica:
$$\text{Predicción típica}(M) = 10^{\frac{1}{N}\log_{10} P(\text{Datos}|M)}.$$
6. Realizá este procedimiento para el modelo Base (M_0) y para el modelo Monty Hall (M_1).

Checkeos rápidos.

- La predicción típica siempre queda entre 0 y 1.
- El valor obtenido no depende del tamaño del dataset, sino del ajuste del modelo.
- Si dos modelos tienen predicción típica muy similar, entonces asignan probabilidades similares a las observaciones.
- Un modelo que asigna mayor predicción típica explica mejor los datos observados.

1.6. Calcular la predicción de los datos con la contribución de todos los modelos.

Nos estamos acercando al cálculo de la posterior de los modelos que venimos trabajando. Recordemos que la posterior representa la creencia que se tiene sobre un modelo, y para actualizar esta creencia sobre los modelos vamos a necesitar la probabilidad total de los datos, $P(\text{Datos})$ (con esto cumplimos con el teorema de bayes), que no es más que la predicción hecha con la contribución de todos los modelos.

$$P(\text{Datos}) \overset{\substack{\text{Regla de}\\ \text{la suma}}}{=} \sum_{\text{Modelo}} P(\text{Modelo}, \text{Datos}) \overset{\substack{\text{Regla de}\\ \text{la producto}}}{=} \sum_{\text{Modelo}} \underbrace{P(\text{Datos}|\text{Modelo})}_{\substack{\text{Predicción hecha}\\ \text{por el modelo}}} \underbrace{P(\text{Modelo})}_{\substack{\text{Creencia en}\\ \text{el modelo}}}$$

Ejercicio: predicción ensamble $P(\textbf{Datos})$

Objetivo. Calcular la predicción total $P(\text{Datos})$ combinando las evidencias de los modelos con el prior de modelos.

Guía (pasos).

1. Elegí un prior para ambos modelos $P(M)$ (por ejemplo uniforme: $P(M_0) = P(M_1) = 1/2$).
2. Calculá $P(\text{Datos} \mid M_0)$ y $P(\text{Datos} \mid M_1)$ (lo tenemos de ejercicios anteriores).
3. Aplicá la regla de la suma: $P(\text{Datos}) = \sum_M P(\text{Datos} \mid M)P(M)$.

Checkeos rápidos.

- $P(\text{Datos})$ queda entre el mínimo y el máximo de $P(\text{Datos} \mid M)$ (promedio ponderado).
- Con prior uniforme, ningún modelo tiene ventaja inicial "por decreto".

1.7. Calcular y graficar el posterior de los modelos sobre los datos simulados

Ahora sí. Tenemos todos los elementos necesarios para calcular el posterior de los modelos.

$$P(\text{Modelo}|\text{Datos}) = \frac{P(\text{Modelo}, \text{Datos})}{P(\text{Datos})}$$

Ejercicio: posterior de modelos + gráfico

Objetivo. Calcular $P(M \mid \text{Datos}_{0:t})$ para cada t y graficar la evolución del posterior de modelos a medida que llegan episodios.

Guía (pasos).

1. Para cada t, tomá el prefijo $\text{Datos}_{0:t}$.
2. Calculá $P(\text{Datos}_{0:t} \mid M)$ para M_0 y M_1.
3. Calculá $P(\text{Datos}_{0:t})$ con la mezcla de modelos.
4. Aplicá Bayes: $P(M \mid \text{Datos}_{0:t}) = \frac{P(\text{Datos}_{0:t}|M)P(M)}{P(\text{Datos}_{0:t})}$.
5. Guardá $P(M_0 \mid \text{Datos}_{0:t})$ y $P(M_1 \mid \text{Datos}_{0:t})$ para graficar.

Checkeos rápidos.

- En cada t, $P(M_0 \mid \text{Datos}_{0:t}) + P(M_1 \mid \text{Datos}_{0:t}) = 1$.
- Si simulaste datos desde M_1, es esperable que $P(M_1 \mid \text{Datos}_{0:t})$ tienda a aumentar con t.
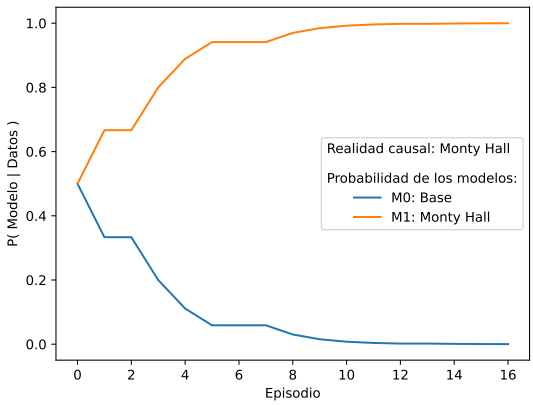
El gráfico resultante se debería ver de la siguiente forma: