Práctica 1 - Parte 2
Argumentos causales alternativos e incertidumbre.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
1er cuatrimestre 2026
UNSAM

Índice

1. Modelo Alternativo **2**
1.1. Calcular el posterior sobre la memoria p. 5
1.2. Calcular la predicción de un episodio dado los datos de los episodios anteriores . . 7
1.3. Calcular la predicción que hace el modelo alternativo M_A sobre todo el conjunto de datos. 8
1.4. Comparar el desempeño del modelo alternativo respecto de los modelos Base y el modelo MontyHall. 10
1.5. Calcular la predicción típica que hace el modelo de los episodios. 11
1.6. Calcular el posterior en los primeros episodios y graficar 13

1. Modelo Alternativo

En esta segunda parte vamos a hacer una vuelta de tuerca: en lugar de asumir que el presentador siempre juega "modo Monty Hall" o siempre juega "modo Base", vamos a asumir que a veces *se acuerda* de tu elección y a veces *se olvida*.

Se provee un archivo de datos `NoMontyHall.csv` que contiene 2000 episodios. Los datos fueron generados con la siguiente realidad causal subyacente:

- La persona que da la pista tiene una probabilidad $p \in [0, 1]$ de **acordarse** de tener en cuenta la caja que reservamos a la hora de dar la pista.
- Esa probabilidad p es **global**: es la misma para todos los episodios.
- En cada episodio particular, la persona se acuerda o no: $a_t \in \{0, 1\}$.
- Si $a_t = 1$ (se acuerda), usa el mecanismo del modelo Monty Hall para dar la pista.
- Si $a_t = 0$ (se olvida), usa el mecanismo del modelo Base.

Checklist:

- Tenés identificado qué cosas ves en el CSV: c_t, s_t y r_t.
- Tenés identificado qué cosas NO ves: p y los a_t.
- Tenés claro que p es común a todos los episodios (por eso "pega" todo junto).

Para especificar matemáticamente el modelo causal vamos a usar la notación gráfica conocida como *factor graph*. La idea (intuición rápida) es que, además de dibujar variables, también dibujamos **mecanismos** (factores) como nodos. Te queda un grafo bipartito: variables por un lado, factores por el otro. Al igual que en redes bayesianas, el producto de esos factores termina siendo la especificación de la conjunta.

Una ventaja práctica: en un factor graph es más natural decir "este mecanismo a veces es uno y a veces es otro", y representarlo mediante la notación de compuertas (*gates*), introducida en el artículo *Causality with gates*.

En el modelo alternativo, ahora la pista depende de 3 variables, por lo que su distribución de probabilidad condicional tiene 3 variables en el condicional. Sin embargo, podemos ser más específicos y mostrar explícitamente que esa distribución de probabilidad condicional es en realidad una mezcla de mecanismos causales probabilísticos.

$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)} \tag{1}$$

Si la persona se olvida de tener en cuenta la caja elegida, $a_t = 0$, la persona de la pista siguiendo el mecanismo causal del modelo Base, $P(s_t|r_t)$. Si la persona se acuerda de tener en cuenta la caja elegida, $a_t = 1$, la persona de la pista siguiendo el mecanismo causal del modelo Monty Hall, $P(s_t|r_t, c_t)$.

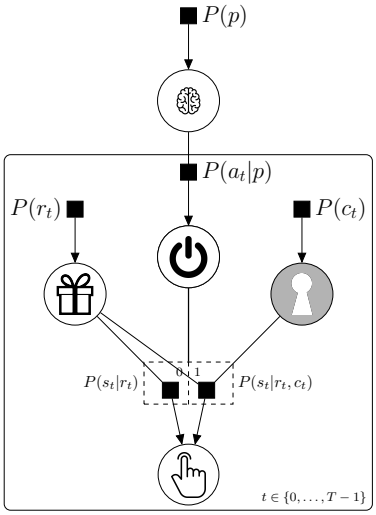

Figura 1: Realidad causal subyacente que generó el conjunto de datos del archivo `NoMontyHall.csv`, especificado mediante la notación de *factor graph*.

Luego, la probabilidad conjunta es

$$P(r_0, c_0, s_0, a_0, \ldots, p|M_2) = P(p) \prod_{t=0}^{T} P(r_t)P(c_t)P(s_t|r_t, M_0)^{1-a_t} P(s_t|r_t, c_t, M_1)^{a_t} P(a_t|p) \tag{2}$$

A diferencia de lo que ocurre en los modelos Base y Monty Hall, en el cual los datos de los diferentes episodios son independientes entre sí, en este modelo hay una variable, la probabilidad p de acordarse, que es común a todos los episodios y los conectan entre sí. Si abrimos las placas con el subíndice t que representa la repetición de los episodios vamos a ver que ellos quedan conectados entre sí por la variable p.

Checklist:

- La ecuación 2 te tiene que "sonar" a: prior de p por un producto de episodios.
- El único "pegamento" entre episodios es p.
- a_t aparece dentro del producto porque es local al episodio.

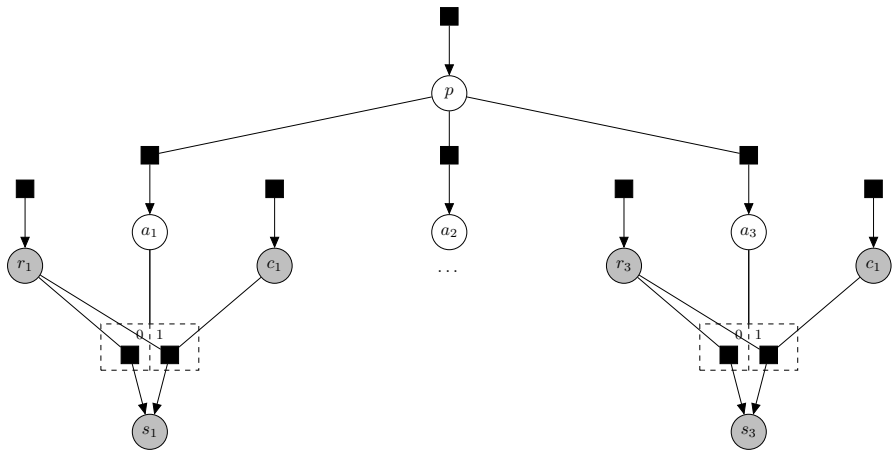

Figura 2: Factor graph del modelo alternativo desplegado. Las variables en blanco son ocultas, y las variables en gris son observadas (disponibles en la base de datos).

El archivo `NoMontyHall.csv` tiene los datos de los episodios: la caja que reservamos c_t, la pista que nos ofrecen s_t, y la posición del regalo r_t. Las variables que hemos agregado para modelar el problema, la probabilidad de acordarse p y las variables de cada episodio que representan si que efectivamente se acuerda o no a, permanecen ocultas. Las variables que se grafican en blanco representan variables ocultas (como la probabilidad de acordarse p y las variables a_t) y las variables en gris representan variables observadas (el regalo, la caja reservada y la pista).

Errores comunes:

- **Síntoma:** no te cierra qué variable estás inferiendo o te queda una implementación incoherente. **Causa probable:** confusión entre a_t y p (a_t cambia por episodio; p es global). **Chequeo/Arreglo:** asegurate de tratar $a_t \in \{0, 1\}$ como variable local y a $p \in [0, 1]$ como el único parámetro compartido.
- **Síntoma:** intentás estimar p mirando 1 episodio, o interpretás p como "probabilidad de Monty Hall en ese episodio". **Causa probable:** lectura incorrecta de p. **Chequeo/Arreglo:** recordá que p se infiere mirando muchos episodios (y en cada episodio se integra a_t).
- **Síntoma:** tus ecuaciones te quedan inmanejables o no ves cómo factorizar productos. **Causa probable:** olvidar que, **condicionalmente a** p, los episodios quedan independientes. **Chequeo/Arreglo:** reescribí la verosimilitud como $\prod_t P(c_t, s_t, r_t \mid p)$ y revisá que la única dependencia global esté en p.

Qué vamos a lograr en esta parte

- Leer un modelo donde hay una variable global (p) que conecta episodios.
- Calcular el posterior $P(p|\text{Datos})$ y usarlo como "memoria" para predecir episodios futuros.
- Trabajar con log-probabilidades para evitar underflow (productos enormes de números chicos).
- Comparar modelos con Bayes factors cuando el posterior directo no es numéricamente estable.

1.1. Calcular el posterior sobre la memoria p.

A diferencia de los modelos Base y Monty Hall, en el modelo alternativo los episodios están conectados entre sí por la memoria p. Cada vez que recibimos nuevos datos, vamos a actualizar la distribución de creencias sobre la memoria p, y usar ese posterior como prior del siguiente evento.

¿Cómo calculamos el posterior de la memoria p? Recordá que, si tenés la conjunta, podés derivar todo con las dos reglas: producto (condicional) y suma (marginal). Revisemos entonces la distribución de probabilidad conjunta del modelo alternativo que se presentó en la ecuación 2, que aquí volvemos a escribir de forma levemente simplificada.

$$P(r_0, c_0, s_0, a_0, \ldots, p) = P(p) \prod_{t=0}^{T} \underbrace{P(r_t)P(c_t)P(s_t|r_t, c_t, a_t)P(a_t|p)}_{P(r_t, c_t, s_t, a_t|p)} \tag{3}$$

Recordar que el posterior sobre hipótesis oculta dado los datos no es más que la distribución de probabilidad condicional, que tiene en el numerador la probabilidad conjunta entre la hipótesis y los datos, y tiene en el denominador la probabilidad conjunta de los datos (integrando todas las posibles hipótesis). Aquí los datos contienen solo la posición del regalo r_t, la caja que reservamos c_t y la pista que nos dan s_t. Nunca sabemos si la persona se acordó o no de tener en cuenta la caja que reservamos para dar la pista, por lo que a_t permanece como variable oculta. Luego, por las reglas de la probabilidad, podemos calcular la conjunta entre la hipótesis p y los eventos observados r_t, c_t, s_t integrando (regla de la suma) las hipótesis ocultas a_t.

$$P(p|\underbrace{r_0, c_0, s_0, \ldots}_{\text{Datos}}) = \frac{\overbrace{\sum_{a_0 \ldots a_T} P(r_0, c_0, s_0, a_0, \ldots, p)}^{P(r_0, c_0, s_0, \ldots, p) = P(\text{Datos}, p)}}{\underbrace{\sum_{p, a_0 \ldots a_T} P(r_0, c_0, s_0, a_0, \ldots, p)}_{P(r_0, c_0, s_0, \ldots) = P(\text{Datos})}} \tag{4}$$

En particular, si revisamos el numerador veremos que lo podemos reescribir de la siguiente forma.

$$\begin{aligned} \sum_{a_0 \ldots a_T} P(r_0, c_0, s_0, a_0, \ldots, p) &\overset{3}{=} \sum_{a_0 \ldots a_T} \left(P(p) \prod_{t=0}^{T} P(r_t, c_t, s_t, a_t|p) \right) \\ &= P(p) \prod_{t=0}^{T} \underbrace{\sum_{a_t} P(r_t, c_t, s_t, a_t|p)}_{P(r_t, c_t, s_t|p)} = \underbrace{P(p)}_{\text{Prior}} \underbrace{\prod_{t=0}^{T} P(r_t, c_t, s_t|p)}_{\text{Verosimilitud}} \end{aligned} \tag{5}$$

Es decir, cuando calculamos el posterior de la memoria p vemos que en la verosimilitud los eventos son independientes entre sí. Cuando estudiemos el flujo de inferencia en estructuras causal vamos

a ver un método más simple para sacar este tipo de conclusiones, en el que se descompone las reglas de la probabilidad como mensajes que se envían los nodos de la red causal (factor graph).

$$P(p|\text{Datos} = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\}) = \frac{\overbrace{\prod_t P(c_t, s_t, r_t|p)}^{\text{Verosimilitud}} \overbrace{P(p)}^{\text{Prior}}}{\sum_p P(p) \prod_t P(c_t, s_t, r_t|p)} \tag{6}$$

Este posterior va a ser importante a la ahora de predecir lo que ocurre con el siguiente evento, lo que haremos en la siguiente sección. Si bien p es continua y hay soluciones más "analíticas", a efectos prácticos alcanza con evaluar un conjunto finito de valores (por ejemplo, 21 valores equidistantes entre 0 y 1).

Ejercicio: posterior de la memoria p

Objetivo. Construir una aproximación discreta de $P(p|\text{Datos})$ en una grilla finita (por ejemplo, 21 valores entre 0 y 1).

Guía (pasos).

1. (Reusar la Parte 1) Asegurate de tener implementadas las predicciones de los dos mecanismos por episodio: Base (M_0) y Monty Hall (M_1).
2. Definí el prior de memoria $P(p)$ (por ejemplo uniforme en $[0, 1]$ sobre la grilla) y el mecanismo $P(a_t \mid p)$ (por ejemplo, $P(a_t = 1 \mid p) = p$).
3. Implementá la verosimilitud de un episodio integrando la variable oculta a_t:

   $$P(c_t, s_t, r_t \mid p) = \sum_{a_t \in \{0,1\}} P(c_t, s_t, r_t \mid a_t)\, P(a_t \mid p).$$

   En la práctica, esto es una mezcla: $P(\cdot \mid a_t{=}1)$ (mecanismo Monty Hall) ponderado por p y $P(\cdot \mid a_t{=}0)$ (mecanismo Base) ponderado por $(1 - p)$.
4. Para cada p de la grilla, calculá algo proporcional a

   $$\tilde{P}(p \mid \text{Datos}) = P(p) \prod_t P(c_t, s_t, r_t \mid p).$$

5. Normalizá en la grilla: $P(p \mid \text{Datos}) = \tilde{P}(p \mid \text{Datos}) \,/\, \sum_{p \in \text{grilla}} \tilde{P}(p \mid \text{Datos})$.

Checkeos rápidos.

- Tu posterior discreta $P(p \mid \text{Datos})$ (en la grilla) tiene que sumar 1.
- Si agregás más episodios, el posterior debería volverse más concentrado (menos plano), salvo que los datos sean muy ambiguos.
- Si calculás todo en log, recordá volver a normalizar correctamente al final.

1.2. Calcular la predicción de un episodio dado los datos de los episodios anteriores

Para calcular la predicción del siguiente episodio dada la información de los eventos anteriores vamos a usar el último posterior de p como prior para el nuevo episodio.

$$P(\text{Episodio}_T = (c_T, s_T, r_T)|\text{Datos}_{0:T-1} = \{(c_0, s_0, r_0), \ldots, (c_{T-1}, s_{T-1}, r_{T-1})\})$$

Recordar que cualquier conclusión que necesitemos alcanzar la podemos obtener aplicando las dos reglas de la probabilidad: la regla de la suma (marginal) y la regla del producto (condicional). En particular, en probabilidad las predicciones se realizan con la contribución de todas las hipótesis.

$$P(c_T, s_T, r_T|\text{Datos}_{0:T-1}) = \sum_p \sum_{a_T} P(c_T, s_T, r_T, a_T, p|\text{Datos}_{0:T-1})$$

Siguiendo la misma linea de razonamiento que hicimos en la sección anterior, podemos llegar a la conclusión que,

$$P(c_T, s_T, r_T|\text{Datos}_{0:T-1}) = \sum_p \sum_{a_T} P(r_T)P(c_T)P(s_T|r_T, c_T, a_T)P(a_T|p)P(p|\text{Datos}_{0:T-1}) \tag{7}$$

Cuando estudiemos el flujo de inferencia en estructuras causales vamos a ver lo simple que se vuelve alcanzar este tipo de conclusiones aplicando el algoritmo suma-producto, que descompone la aplicación de las reglas de la probabilidad como mensajes que se envían los nodos de las red causal (factor graph). Acá el punto importante es no olvidarse de utilizar el último posterior, $P(p|\text{Datos}_{0:T-1})$ para predecir el siguiente evento T.

Errores comunes:

- **Síntoma:** la predicción del episodio siguiente no cambia aunque agregues datos previos. **Causa probable:** usaste $P(p)$ en lugar de $P(p \mid \text{Datos}_{0:T-1})$. **Chequeo/Arreglo:** inspeccioná la función de predicción y confirmá que los pesos sobre p vengan del posterior entrenado con datos previos.
- **Síntoma:** tu predicción depende de un valor fijo de a_T o te queda un caso sin definición. **Causa probable:** olvidaste marginalizar a_T (no se observa). **Chequeo/Arreglo:** asegurate de que $P(c_T, s_T, r_T \mid p)$ incluya la suma sobre $a_T \in \{0, 1\}$.
- **Síntoma:** terminás implementando un estimador de p y no una predicción de episodios. **Causa probable:** objetivo confundido. **Chequeo/Arreglo:** verificá que la salida final sea $P(c_T, s_T, r_T \mid \text{Datos}_{0:T-1})$ (un número), no una distribución nueva sobre p.

Ejercicio: predecir el próximo episodio usando memoria

Objetivo. Calcular la predicción de un episodio candidato (c_T, s_T, r_T) integrando incertidumbre sobre p y a_T, usando $P(p \mid \text{Datos}_{0:T-1})$.

Guía (pasos).

1. Entrada: un episodio candidato (c_T, s_T, r_T) y los datos previos $\text{Datos}_{0:T-1}$.
2. Calculá (o recuperá) el posterior $P(p \mid \text{Datos}_{0:T-1})$ en tu grilla.
3. Para cada p en la grilla, calculá $P(c_T, s_T, r_T \mid p)$ (que ya integra a_T como en el ejercicio anterior).
4. Promediá sobre p usando el posterior como pesos:

$$P(c_T, s_T, r_T \mid \text{Datos}_{0:T-1}) = \sum_{p \in \text{grilla}} P(c_T, s_T, r_T \mid p)\, P(p \mid \text{Datos}_{0:T-1}).$$

Checkeos rápidos.

- La salida $P(c_T, s_T, r_T \mid \text{Datos}_{0:T-1})$ queda entre 0 y 1.
- Si reemplazás $P(p \mid \text{Datos}_{0:T-1})$ por $P(p)$, el resultado debería cambiar (ese es el punto de la memoria).
- Si probás varios episodios candidatos, los más compatibles con los datos previos deberían tener mayor probabilidad.

1.3. Calcular la predicción que hace el modelo alternativo M_A sobre todo el conjunto de datos.

Calcular la verosimilitud del modelo alternativo como el producto de las predicciones de cada uno de los episodios dado los episodios anteriores.

$$P(\text{Datos}_{0:T}|M_A) = P(\text{Episodio}_0|M_A)P(\text{Episodio}_1|\text{Datos}_0, M_A)P(\text{Episodio}_2|\text{Datos}_{0:1}, M_A)\ldots$$

La predicción sobre un conjunto de datos grandes necesariamente resulta ser un número muy cercano a 0. Esto ocurre porque los elementos del producto son probabilidades, números entre 0 y 1, por lo que a medida que vamos agregando episodios este número se va acercando tanto al cero que deja de poder ser representado por una computadora. Para poder expresarlo en una computadora, vamos a calcular el exponente asociado a ese número, que crece a una velocidad exponencialmente más lenta.

$$\log_{10} P(\text{Datos}_{0:T}|M_A) = \log_{10} P(\text{Episodio}_0|M_A) + \log_{10} P(\text{Episodio}_1|\text{Datos}_0, M_A) + \ldots$$

Ejercicio: verosimilitud del modelo alternativo en código

Objetivo. Calcular la verosimilitud del modelo alternativo sobre un dataset grande de forma numéricamente estable, trabajando en log:

$$\log_{10} P(\text{Datos}_{0:T} \mid M_A) = \sum_{t=0}^{T} \log_{10} P(\text{Episodio}_t \mid \text{Datos}_{0:t-1}, M_A).$$

Guía (pasos).

1. Definí una función que compute $P(\text{Episodio}_t \mid \text{Datos}_{0:t-1}, M_A)$.
2. Adentro, integrá incertidumbre sobre p usando $P(p \mid \text{Datos}_{0:t-1})$ y sobre a_t (porque no se observa).
3. Construí una función que recorra $t = 0, \ldots, T$ y acumule la suma de logs (en vez de multiplicar probabilidades).
4. Guardá (opcionalmente) la secuencia de predicciones por episodio antes del log para depurar (si aparece un 0 o un valor raro, lo encontrás rápido).

Checkeos rápidos.

- Si te da 0 cuando multiplicás probabilidades, no es que el modelo sea imposible: es underflow numérico (por eso usás log).
- En log, los productos pasan a ser sumas (mucho más estable).
- Si comparás modelos con log-verosimilitud, comparás órdenes de magnitud de forma directa.

Errores comunes:

- **Síntoma:** la verosimilitud te da 0 para datasets grandes. **Causa probable:** underflow por multiplicar muchas probabilidades. **Chequeo/Arreglo:** acumulá en log (producto $\rightarrow$ suma) y recién al final, si hace falta, volvé de log a escala normal.
- **Síntoma:** el código tarda mucho y es difícil de depurar. **Causa probable:** recalculás desde cero $P(p \mid \text{Datos}_{0:t-1})$ en cada t sin guardar nada. **Chequeo/Arreglo:** cacheá/guardá posteriors intermedios o la secuencia de predicciones por episodio para reutilizar y testear por partes.
- **Síntoma:** el modelo alternativo no refleja aprendizaje secuencial. **Causa probable:** usaste el posterior equivocado para predecir (o no usaste ninguno). **Chequeo/Arreglo:** confirmá que la predicción del episodio t use $P(p \mid \text{Datos}_{0:t-1})$.

1.4. Comparar el desempeño del modelo alternativo respecto de los modelos Base y el modelo MontyHall.

Cuando trabajamos con el exponente de las predicciones no vamos a poder calcular el posterior de los modelos directamente. En estos casos, para comparar el desempeño de los modelos lo que hacemos es comparar modelos de a pares.

$$\frac{P(M_i|\text{Datos})}{P(M_j|\text{Datos})} = \frac{P(\text{Datos}|M_i)P(M_i)}{P(\text{Datos}|M_j)P(M_j)} \stackrel{*}{=} \underbrace{\frac{P(\text{Datos}|M_i)}{P(\text{Datos}|M_j)}}_{\text{Bayes factor}} \tag{8}$$

Al dividir el valor a posteriori de los dos modelos alternativos i y j se cancela el denominador constante teorema de Bayes, $P(\text{Datos})$. Esa es la primera transformación que hacemos. Además, en el caso de que tengamos un prior uniforme entre modelos, $P(M_i) \stackrel{*}{=} P(M_j)$, también se cancelan los priors y la comparación del posterior de los modelos se reduce a la comparación de sus predicciones, $P(\text{Datos}|M)$. Este cociente entre predicciones de los modelos se conoce como *Bayes factor*.

Como hemos mencionado en la sección anterior, las predicciones sobre conjuntos de datos grandes conviene expresarlas en escala logarítmica. Esta transformación tiene la ventaja adicional de hacer que el cociente sea simétrico.

$$\log_{10} \underbrace{\frac{P(\text{Datos}|M_i)}{P(\text{Datos}|M_j)}}_{\text{Bayes factor}} = \underbrace{\log_{10} P(\text{Datos}|M_i) - \log_{10} P(\text{Datos}|M_j)}_{\text{Diferencia predictiva en órdenes de magnitud}} \tag{9}$$

Para interpretar el significado del exponente del Bayes factor (9) es importante recordar que la verosimilitud de los modelos $P(\text{Datos}|M)$ funciona como filtro de la creencia previa. En base 10, una diferencia de un orden de magnitud significa que uno de los modelos preservó 10 veces más creencia que el otro, dos ordenes de magnitud significa que un modelos preservó 100 veces más creencia que el otro, y así sucesivamente. Aunque estos números parezcan extraordinarios, cuatro órdenes de magnitud se considera en el límite de una diferencia no concluyente. Cuando las bases de datos crecen, la diferencia en órdenes de magnitud continúan creciendo, por lo que es normal ver diferencia de 10000, pero en órdenes de magnitud! En esos casos, para ganar intuición es útil calcular la predicción "típica".

Ejercicio: Bayes factor en log

Objetivo. Comparar el desempeño predictivo de dos modelos M_i y M_j usando el Bayes factor en escala logarítmica.

Guía (pasos).

1. Calculá (o reutilizá) $\log_{10} P(\text{Datos} \mid M_i)$ y $\log_{10} P(\text{Datos} \mid M_j)$.
2. Si asumís prior uniforme entre modelos, aplicá:
$$\log_{10} \mathrm{BF}_{i,j} = \log_{10} P(\text{Datos} \mid M_i) - \log_{10} P(\text{Datos} \mid M_j).$$
3. Interpretá el resultado como una diferencia en órdenes de magnitud (base 10) a favor de M_i frente a M_j.

Checkeos rápidos.

- Simetría: $\log_{10} \mathrm{BF}_{i,j} = -\log_{10} \mathrm{BF}_{j,i}$.
- Si ambos modelos predicen igual de bien, la diferencia debería quedar cerca de 0.
- Si uno de los modelos da un log-verosimilitud muchísimo menor (más negativo), el Bayes factor lo penaliza fuertemente.

1.5. Calcular la predicción típica que hace el modelo de los episodios.

Dado que la predicción sobre un conjunto de datos se descompone como el producto de las predicciones, la predicción típica es su media geométrica, la raiz N-ésima de la predicción sobre todo el conjunto de datos (donde N es el tamaño del conjunto de datos $N = |\text{Datos}|$).

$$\text{Predicción típica} := \underbrace{P(\text{Datos} = \{d_1, d_2, \ldots, d_N\}|M)^{1/N}}_{\text{Media geométrica}} \tag{10}$$

Decimos que es típica justamente porque al reemplazar cada una de las predicciones individuales que componen en la secuencia de predicciones por el valor de la media geometrica volvemos a obtener exactamente el valor de la predicción sobre todo el conjunto de datos.

$$\begin{aligned} P(\text{Datos} = \{d_1, d_2, \ldots, d_N\}|M) &= P(d_1|M)P(d_2|d_1, M)\ldots \\ &= \prod_{i \in \{1,\ldots,N\}} \text{Predicción típica} = \text{Predicción típica}^N \end{aligned} \tag{11}$$

Para calcular la media geométrica vamos a enfrentar el mismo problema de representación computacional que señalamos respecto de las predicciones sobre conjuntos de datos grandes. Por eso, para calcularla hay que trabajar con el exponente de la predicción. La forma más sencilla es ir guardando la suma de los exponentes de las predicciones individuales, luego obtener el exponente promedio, y finalmente transformar ese exponente en número.

$$\begin{aligned} \text{Predicción típica} &= 10^{\overbrace{\log_{10}(P(d_1|M)P(d_2|d_1, M)\ldots)^{1/N}}^{\text{Exponente de la predicción típica}}} \\ &= 10^{\frac{1}{N}\left(\log_{10} P(d_1|M) + \log_{10} P(d_2|d_1, M) + \ldots\right)} \end{aligned} \tag{12}$$

Este número representa la predicción típica, una probabilidad entre 0 y 1. Sirve para "humanizar" evidencias del estilo 10^{-68} sin perder la interpretación multiplicativa.

Ejercicio: predicción típica (media geométrica) en código

Objetivo. Calcular la predicción típica (media geométrica) para "humanizar" evidencias muy pequeñas sin perder interpretación multiplicativa.

Guía (pasos).

1. Elegí N como la cantidad total de factores del producto que define tu $P(\text{Datos} \mid M)$ (por ejemplo, si tu producto es "uno por episodio", entonces $N = T$).
2. Reutilizá tu valor $\log_{10} P(\text{Datos} \mid M)$.
3. Calculá el exponente promedio: $\frac{1}{N} \log_{10} P(\text{Datos} \mid M)$.
4. Transformá a probabilidad típica:
$$\text{Predicción típica} = 10^{\frac{1}{N} \log_{10} P(\text{Datos}|M)}.$$
5. Repetí para cada modelo que quieras comparar.

Checkeos rápidos.

- La predicción típica siempre queda entre 0 y 1.
- Es útil para comparar modelos sin mirar números del estilo 10^{-68}.
- Si dos modelos tienen predicción típica muy parecida, necesitás muchos datos para que la evidencia acumulada se separe mucho.

1.6. Calcular el posterior en los primeros episodios y graficar

Para poder graficar cómo cambia la creencia de los modelos a medida que vamos observando episodios vamos a calcular el posterior de los tres modelos en los primeros 60 episodios.

Ejercicio: gráfico del posterior final

Objetivo. Calcular y graficar la evolución del posterior $P(M \mid \text{Datos}_{0:t})$ para los tres modelos (M_0, M_1, M_A) en los primeros 60 episodios.

Guía (pasos).

1. Para cada $t = 0, \ldots, 59$, construí el prefijo $\text{Datos}_{0:t}$.
2. Calculá (o aproximá en log cuando corresponda) $P(\text{Datos}_{0:t} \mid M_0)$, $P(\text{Datos}_{0:t} \mid M_1)$ y $P(\text{Datos}_{0:t} \mid M_A)$.
3. Elegí un prior de modelos $P(M)$ (por ejemplo uniforme entre los tres).
4. Convertí esas predicciones en posterior por Bayes (cuidando la normalización). Guardá $P(M \mid \text{Datos}_{0:t})$ para cada M.
5. Graficá las tres curvas en función de t.

Checkeos rápidos.

- En cada t, $P(M_0 \mid \text{Datos}_{0:t}) + P(M_1 \mid \text{Datos}_{0:t}) + P(M_A \mid \text{Datos}_{0:t}) = 1$.
- Cambiar el orden de los primeros 60 episodios no debería cambiar el posterior final, pero sí la trayectoria (porque M_A usa "posterior como prior").
- Si tus cálculos pasan por log, asegurate de normalizar correctamente para volver a probabilidades.
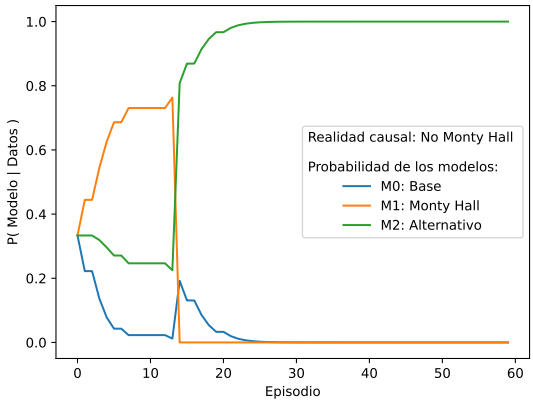
El gráfico resultante se debería ver de la siguiente forma: