

Práctica 1 - Parte 2

Argumentos causales alternativos e incertidumbre.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
1er cuatrimestre 2026
UNSAM

Índice

1. Modelo Alternativo	1
1.1. Calcular el posterior sobre la memoria p .	3
1.2. Calcular la predicción de un episodio dado los datos de los episodios anteriores	4
1.3. Calcular la predicción que hace el modelo alternativo M_A sobre todo el conjunto de datos.	5
1.4. Comparar el desempeño del modelo alternativo respecto de los modelos Base y el modelo MontyHall.	6
1.5. Calcular la predicción típica que hace el modelo de los episodios.	6
1.6. Calcular el posterior en los primeros episodios y graficar	7

Resumen

Sabemos que los modelos causales que se corresponden con la realidad causal subyacente son óptimos en términos práctico, no se puede mejorar su predicción. En esta práctica, entonces, vamos a especificar un modelo causal alternativo a Monty Hall siguiendo nuestro conocimiento experto de que la persona que da la pista a veces se puede olvidar de tener en cuenta la caja que elegimos. El modelo propuesto contiene un mecanismo causal dinámico, que cambia de comportamiento según si la persona se acuerda o se olvida. Vamos a hacer inferencia de variables internas (la memoria o probabilidad de acordarse) y también vamos a evaluar este modelo causal respecto de los anteriores.

1. Modelo Alternativo

En esta segunda parte vamos a hacer una vuelta de tuerca: en lugar de asumir que el presentador siempre juega “modo Monty Hall” o siempre juega “modo Base”, vamos a asumir que a veces *se acuerda* de tu elección y a veces *se olvida*.

Se provee un archivo de datos `NoMontyHall.csv` que contiene 2000 episodios. Los datos fueron generados con la siguiente realidad causal subyacente:

- La persona que da la pista tiene una probabilidad $p \in [0, 1]$ de **acordarse** de tener en cuenta la caja que reservamos a la hora de dar la pista.
- Esa probabilidad p es **global**: es la misma para todos los episodios.
- En cada episodio particular, la persona se acuerda o no: $a_t \in \{0, 1\}$.
- Si $a_t = 1$ (se acuerda), usa el mecanismo del modelo Monty Hall para dar la pista.
- Si $a_t = 0$ (se olvida), usa el mecanismo del modelo Base.

Para especificar matemáticamente el modelo causal vamos a usar la notación gráfica conocida como *factor graph*. La idea (intuición rápida) es que, además de dibujar variables, también dibujamos **mecanismos** (factores) como nodos. Te queda un grafo bipartito: variables por un lado, factores por el otro. Al igual que en redes bayesianas, el producto de esos factores termina siendo la especificación de la conjunta.

Una ventaja práctica: en un factor graph es más natural decir “este mecanismo a veces es uno y a veces es otro”, y representarlo mediante la notación de compuertas (*gates*), introducida en el artículo *Causality with gates*.

En el modelo alternativo, ahora la pista depende de 3 variables, por lo que su distribución de probabilidad condicional tiene 3 variables en el condicional. Sin embargo, podemos ser más específicos y mostrar explícitamente que esa distribución de probabilidad condicional es en realidad una mezcla de mecanismos causales probabilísticos.

$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)} \quad (1)$$

Si la persona se olvida de tener en cuenta la caja elegida, $a_t = 0$, la persona de la pista sigue el mecanismo causal del modelo Base, $P(s_t|r_t)$. Si la persona se acuerda de tener en cuenta la caja elegida, $a_t = 1$, la persona de la pista sigue el mecanismo causal del modelo Monty Hall, $P(s_t|r_t, c_t)$.




Figura 1: Realidad causal subyacente que generó el conjunto de datos del archivo `NoMontyHall.csv`, especificado mediante la notación de *factor graph*.

Luego, la probabilidad conjunta es

$$P(r_0, c_0, s_0, a_0, \dots, p|M_A) = P(p) \prod_{t=0}^{T-1} P(r_t)P(c_t)P(s_t|r_t, M_0)^{1-a_t} P(s_t|r_t, c_t, M_1)^{a_t} P(a_t|p) \quad (2)$$

A diferencia de lo que ocurre en los modelos Base y Monty Hall, en el cual los datos de los diferentes episodios son independientes entre sí, en este modelo hay una variable, la probabilidad p de acordarse, que es común a todos los episodios y los conecta entre sí. Si abrimos las placas con el subíndice t que representa la repetición de los episodios vamos a ver que ellos quedan conectados entre sí por la variable p .




Figura 2: Factor graph del modelo alternativo desplegado. Las variables en blanco son ocultas, y las variables en gris son observadas (disponibles en la base de datos).

El archivo `NoMontyHall.csv` tiene los datos de los episodios: la caja que reservamos c_t , la pista que nos ofrecen s_t , y la posición del regalo r_t . Las variables que hemos agregado para modelar el problema, la probabilidad de acordarse p y las variables de cada episodio que representan si efectivamente se acuerda o no a_t , permanecen ocultas. Las variables que se grafican en blanco representan variables ocultas (como la probabilidad de acordarse p y las variables a_t) y las variables en gris representan variables observadas (el regalo, la caja reservada y la pista).

1.1. Calcular el posterior sobre la memoria p .

A diferencia de los modelos Base y Monty Hall, en el modelo alternativo los episodios están conectados entre sí por la memoria p . Cada vez que recibimos nuevos datos, vamos a actualizar la distribución de creencias sobre la memoria p , y usar ese posterior como prior del siguiente evento.

¿Cómo calculamos el posterior de la memoria p ? Recordá que, si tenés la conjunta, podés derivar todo con las dos reglas: producto (condicional) y suma (marginal). Revisemos entonces la distribución de probabilidad conjunta del modelo alternativo que se presentó en la ecuación 2, que aquí volvemos a escribir de forma levemente simplificada.

$$P(r_0, c_0, s_0, a_0, \dots, p) = P(p) \prod_{t=0}^{T-1} \underbrace{P(r_t)P(c_t)P(s_t|r_t, c_t, a_t)P(a_t|p)}_{P(r_t, c_t, s_t, a_t|p)} \quad (3)$$

Recordar que el posterior sobre hipótesis oculta dado los datos no es más que la distribución de probabilidad condicional, que tiene en el numerador la probabilidad conjunta entre la hipótesis y los datos, y tiene en el denominador la probabilidad conjunta de los datos (integrando todas las posibles hipótesis). Aquí los datos contienen solo la posición del regalo r_t , la caja que reservamos c_t y la pista que nos dan s_t . Nunca sabemos si la persona se acordó o no de tener en cuenta la caja que reservamos para dar la pista, por lo que a_t permanece como variable oculta. Luego, por las reglas de la probabilidad, podemos calcular la conjunta entre la hipótesis p y los eventos observados r_t, c_t, s_t integrando (regla de la suma) las hipótesis ocultas a_t .

$$P(p | \underbrace{r_0, c_0, s_0, \dots}_{\text{Datos}}) = \frac{\overbrace{\sum_{a_0 \dots a_{T-1}}^{P(r_0, c_0, s_0, \dots, p) = P(\text{Datos}, p)} P(r_0, c_0, s_0, a_0, \dots, p)}}{\underbrace{\sum_{p, a_0 \dots a_{T-1}} P(r_0, c_0, s_0, a_0, \dots, p)}_{P(r_0, c_0, s_0, \dots) = P(\text{Datos})}} \quad (4)$$

En particular, si revisamos el numerador veremos que lo podemos reescribir de la siguiente forma.

$$\begin{aligned}
\sum_{a_0 \dots a_{T-1}} P(r_0, c_0, s_0, a_0, \dots, p) &\stackrel{3}{=} \sum_{a_0 \dots a_{T-1}} \left(P(p) \prod_{t=0}^{T-1} P(r_t, c_t, s_t, a_t | p) \right) \\
&= P(p) \prod_{t=0}^{T-1} \underbrace{\sum_{a_t} P(r_t, c_t, s_t, a_t | p)}_{P(r_t, c_t, s_t | p)} = \underbrace{P(p)}_{\text{Prior}} \underbrace{\prod_{t=0}^{T-1} P(r_t, c_t, s_t | p)}_{\text{Verosimilitud}}
\end{aligned} \tag{5}$$

Es decir, cuando calculamos el posterior de la memoria p vemos que en la verosimilitud los eventos son independientes entre sí. Cuando estudiemos el flujo de inferencia en estructuras causal vamos a ver un método más simple para sacar este tipo de conclusiones, en el que se descompone las reglas de la probabilidad como mensajes que se envían los nodos de la red causal (factor graph).

$$P(p | \text{Datos} = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\}) = \frac{\overbrace{\prod_t P(c_t, s_t, r_t | p)}^{\text{Verosimilitud}} \overbrace{P(p)}^{\text{Prior}}}{\sum_p P(p) \prod_t P(c_t, s_t, r_t | p)} \tag{6}$$

Este posterior va a ser importante a la hora de predecir lo que ocurre con el siguiente evento, lo que haremos en la siguiente sección. Si bien p es continua y hay soluciones más “analíticas”, a efectos prácticos alcanza con evaluar un conjunto finito de valores (por ejemplo, 21 valores equidistantes entre 0 y 1).

Objetivo: calcular el posterior de la memoria p .

1. Reusar la práctica 1, las implementaciones de los mecanismos de la psita del modelo Base (M_0) y el modelo Monty Hall (M_1).
2. Definí el prior de memoria $P(p)$ (por ejemplo, uniforme en $[0, 1]$ sobre la grilla) y el mecanismo $P(a_t | p)$ (por ejemplo, $P(a_t = 1 | p) = p$).
3. Implementá la verosimilitud de un episodio integrando la variable oculta a_t :

$$P(c_t, s_t, r_t | p) = \sum_{a_t \in \{0,1\}} P(c_t, s_t, r_t | a_t) P(a_t | p).$$

En la práctica, esto es una mezcla: $P(\cdot | a_t=1)$ (mecanismo Monty Hall) ponderado por p y $P(\cdot | a_t=0)$ (mecanismo Base) ponderado por $(1 - p)$.

4. Para cada p de la grilla, calculá el denominador del posterior

$$P(p, \text{Datos}) = P(p) \prod_t P(c_t, s_t, r_t | p).$$

5. Luego normalizá la grilla: $P(p | \text{Datos}) = P(p, \text{Datos}) / \sum_{p \in \text{grilla}} P(p, \text{Datos})$.

1.2. Calcular la predicción de un episodio dado los datos de los episodios anteriores

Para calcular la predicción del siguiente episodio dada la información de los eventos anteriores vamos a usar el último posterior de p como prior para el nuevo episodio.

$$P(\text{Episodio}_T = (c_T, s_T, r_T) | \text{Datos}_{0:T-1} = \{(c_0, s_0, r_0), \dots, (c_{T-1}, s_{T-1}, r_{T-1})\})$$

Recordá que cualquier conclusión que necesitemos alcanzar la podemos obtener aplicando las dos reglas de la probabilidad: la regla de la suma (marginal) y la regla del producto (condicional). En particular, en probabilidad las predicciones se realizan con la contribución de todas las hipótesis.

$$P(c_T, s_T, r_T | \text{Datos}_{0:T-1}) = \sum_{p \in \text{grilla}} \sum_{a_T} P(c_T, s_T, r_T, a_T, p | \text{Datos}_{0:T-1})$$

Siguiendo la misma línea de razonamiento que hicimos en la sección anterior, podemos llegar a la conclusión que,

$$P(c_T, s_T, r_T | \text{Datos}_{0:T-1}) = \sum_{p \in \text{grilla}} \sum_{a_T} P(r_T) P(c_T) P(s_T | r_T, c_T, a_T) P(a_T | p) P(p | \text{Datos}_{0:T-1}) \quad (7)$$

Cuando estudiemos el flujo de inferencia en estructuras causales vamos a ver lo simple que se vuelve alcanzar este tipo de conclusiones aplicando el algoritmo suma-producto, que descompone la aplicación de las reglas de la probabilidad como mensajes que se envían los nodos de la red causal (factor graph). Acá el punto importante es no olvidarse de utilizar el último posterior, $P(p | \text{Datos}_{0:T-1})$, para predecir el siguiente evento T .

Objetivo: predecir el próximo episodio con la información previa.

1. Dado un episodio (c_T, s_T, r_T) y los episodios previos $\text{Datos}_{0:T-1}$, calculá el posterior $P(p | \text{Datos}_{0:T-1})$.
2. Para cada p en la grilla, calculá $P(c_T, s_T, r_T | p)$ (que ya integra a_T como en el ejercicio anterior).
3. Promediá sobre p usando el posterior como pesos:

$$P(c_T, s_T, r_T | \text{Datos}_{0:T-1}) = \sum_{p \in \text{grilla}} P(c_T, s_T, r_T | p) P(p | \text{Datos}_{0:T-1}).$$

1.3. Calcular la predicción que hace el modelo alternativo M_A sobre todo el conjunto de datos.

Calcular la verosimilitud del modelo alternativo como el producto de las predicciones de cada uno de los episodios dado los episodios anteriores.

$$P(\text{Datos}_{0:T} | M_A) = P(\text{Episodio}_0 | M_A) P(\text{Episodio}_1 | \text{Datos}_0, M_A) P(\text{Episodio}_2 | \text{Datos}_{0:1}, M_A) \dots$$

La predicción sobre un conjunto de datos grandes necesariamente resulta ser un número muy cercano a 0. Esto ocurre porque los elementos del producto son probabilidades, números entre 0 y 1, por lo que a medida que vamos agregando episodios este número se va acercando tanto al cero que deja de poder ser representado por una computadora. Para poder expresarlo en una computadora, vamos a calcular el exponente asociado a ese número, que crece a una velocidad exponencialmente más lenta.

$$\log_{10} P(\text{Datos}_{0:T} | M_A) = \log_{10} P(\text{Episodio}_0 | M_A) + \log_{10} P(\text{Episodio}_1 | \text{Datos}_0, M_A) + \dots$$

Objetivo: verosimilitud del modelo alternativo. Calcular la verosimilitud del modelo alternativo sobre un dataset grande de forma numéricamente estable, trabajando en log:

$$\log_{10} P(\text{Datos}_{0:T} | M_A) = \sum_{t=0}^{T-1} \log_{10} P(\text{Episodio}_t | \text{Datos}_{0:t-1}, M_A).$$

1. Predecí el siguiente episodio, $P(\text{Episodio}_t | \text{Datos}_{0:t-1}, M_A)$.
2. Acumulá la suma de log predicciones.

1.4. Comparar el desempeño del modelo alternativo respecto de los modelos Base y el modelo MontyHall.

En la unidad anterior aprendiste a calcular el Bayes factor para comparar el desempeño predictivo entre el modelo Base y el modelo Monty Hall. En esta práctica, retomamos ese procedimiento, pero ahora extendiéndolo para incluir al modelo alternativo (MA), que incorpora la incertidumbre sobre la memoria del presentador.

El objetivo es que puedas comparar, en escala logarítmica, cómo se desempeñan los tres modelos (Base, Monty Hall y Alternativo) sobre el mismo conjunto de datos, interpretando las diferencias en órdenes de magnitud a favor de uno u otro modelo.

Así, podrás evaluar directamente el impacto de considerar la memoria imperfecta del presentador en la explicación de los datos.

Objetivo: Bayes factor en escala logarítmica. Comparar el desempeño predictivo de los modelos Base (M_0), Monty Hall (M_1) y Alternativo (M_A) usando el Bayes factor en escala logarítmica.

1. Calculá las sumas acumuladas de $\log_{10} P(\text{Datos} \mid M_0)$, $\log_{10} P(\text{Datos} \mid M_1)$ y $\log_{10} P(\text{Datos} \mid M_A)$.
2. Calcular el Bayes factor. En escala logarítmica son simétricos:

$$\log_{10} \frac{P(\text{Datos} \mid M_i)}{P(\text{Datos} \mid M_j)} = \log_{10} P(\text{Datos} \mid M_i) - \log_{10} P(\text{Datos} \mid M_j).$$

Con esta convención, valores positivos favorecen a M_i y valores negativos favorecen a M_j .

3. Aplicá las combinaciones que te interesen:

$$\log_{10} \text{BF}_{0,1} = \log_{10} P(\text{Datos} \mid M_0) - \log_{10} P(\text{Datos} \mid M_1).$$

$$\log_{10} \text{BF}_{0,A} = \log_{10} P(\text{Datos} \mid M_0) - \log_{10} P(\text{Datos} \mid M_A).$$

$$\log_{10} \text{BF}_{1,A} = \log_{10} P(\text{Datos} \mid M_1) - \log_{10} P(\text{Datos} \mid M_A).$$

Checkeos rápidos.

- Simetría: $\log_{10} \text{BF}_{0,1} = -\log_{10} \text{BF}_{1,0}$.
- Si ambos modelos predicen igual de bien, la diferencia debería quedar cerca de 0.
- Si uno de los modelos da un log-verosimilitud muchísimo menor (más negativo), el Bayes factor lo penaliza fuertemente.

1.5. Calcular la predicción típica que hace el modelo de los episodios.

En la unidad anterior calculaste la predicción típica (media geométrica) para los modelos Base y Monty Hall, lo que te permitió interpretar la probabilidad promedio que cada modelo asigna a una observación elemental de los datos.

En esta práctica, aplicarás el mismo procedimiento, pero ahora también para el modelo alternativo (M_A), que introduce la incertidumbre sobre la memoria del presentador.

De este modo, podrás comparar la predicción típica de los tres modelos y analizar cómo la incorporación del modelo alternativo modifica la interpretación sobre cuál modelo explica mejor los episodios observados.

Objetivo: calcular la predicción típica (media geométrica). Cuando hay muchos datos necesitamos trabajar en escala logarítmica para calcular su valor.

1. Definí N como la cantidad de datos observados: la cantidad total de episodios $\times 3$ (cada episodio tiene 3 datos).
2. Reutilizá el valor de $\log_{10} P(\text{Datos} \mid M)$ calculado en el ejercicio anterior.
3. Calculá el exponente promedio: $\frac{1}{N} \log_{10} P(\text{Datos} \mid M)$.
4. Transformá este valor a predicción típica:

$$\text{Predicción típica}(M) = 10^{\frac{1}{N} \log_{10} P(\text{Datos} \mid M)}.$$

5. Realizá este procedimiento para los tres modelos: Base (M_0), Monty Hall (M_1) y Alternativo (M_A).

1.6. Calcular el posterior en los primeros episodios y graficar

Para poder graficar cómo cambia la creencia de los modelos a medida que vamos observando episodios, vamos a calcular el posterior de los tres modelos en los primeros 60 episodios.

Objetivo: gráfico del posterior final. Calcular y graficar la evolución del posterior $P(M \mid \text{Datos}_{0:t})$ para los tres modelos (M_0 , M_1 , M_A) en los primeros 60 episodios.

1. Para cada $t = 0, \dots, 59$, construí el prefijo $\text{Datos}_{0:t}$.
2. Calculá (o aproximá en log cuando corresponda) $P(\text{Datos}_{0:t} \mid M_0)$, $P(\text{Datos}_{0:t} \mid M_1)$ y $P(\text{Datos}_{0:t} \mid M_A)$.
3. Elegí un prior de modelos $P(M)$ (por ejemplo uniforme entre los tres).
4. Convertí esas predicciones en posterior por Bayes (cuidando la normalización). Guardá $P(M \mid \text{Datos}_{0:t})$ para cada M .
5. Graficá las tres curvas en función de t .

El gráfico resultante se debería ver de la siguiente forma:

