

Práctica 2 – Parte 1

Métodos de inferencia.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
1er cuatrimestre 2026
UNSAM

Índice

1. Modelos polinomiales de complejidad creciente	1
1.1. Generar 20 datos alrededor de un período de una sinoidal	3
1.2. Graficar el valor de máxima verosimilitud obtenido por los modelos polinomiales de grado 0 a 9	4
1.3. Graficar las curvas obtenidas con cada modelo mediante máxima verosimilitud . .	5
1.4. Evaluación de la predicción “en línea” que hacen los modelos ajustados por máxima verosimilitud	6
1.5. El balance natural de las reglas de la probabilidad	7
1.6. Cómo se explica el balance natural de las reglas de la probabilidad	8
2. Efecto causal del sexo biológico sobre la altura.	10
2.1. Abrir el archivo <code>alturas.csv</code> y visualizar los datos	10
2.2. Definir 3 modelos causales alternativos	11
2.3. Computar la evidencia de los modelos causales alternativos	11
2.4. Computar la media geométrica de los modelos causales alternativos	11
2.5. Computar el posterior de los modelos	12

Resumen

En esta práctica nos interesa la evaluación de modelos lineales alternativos de complejidad creciente. En el primer ejercicio vamos a comparar el comportamiento de la regresión lineal que selecciona una única hipótesis mediante máxima verosimilitud respecto del desempeño de la regresión lineal bayesiana que evalúa todo el espacio de hipótesis. Veremos que la aplicación estricta de las reglas de la probabilidad no produce overfitting. En el segundo ejercicio vamos a evaluar modelos causales de complejidad creciente en un caso real simple, y veremos que el modelo seleccionado se ajusta a nuestras intuiciones basadas en el conocimiento experto.

1. Modelos polinomiales de complejidad creciente

La gran mayoría de los modelos de inteligencia artificial, incluyendo las redes neuronales, se construyen a partir de modelos que postulan relaciones “lineales” entre las hipótesis. En esta práctica vas a ver cómo los métodos de inferencia que usamos determinan qué tan bien podemos evaluar y comparar modelos.

El modelo más básico es la famosa regresión lineal. Dado un conjunto de datos $\{(x_1, y_1), \dots, (x_T, y_T)\}$, un modelo causal lineal afirma que el valor de la variable y_i se genera en función de x_i y un conjunto de hipótesis ocultas h , tal que

$$y \leftarrow h_0 + h_1 \cdot x$$

h_0 representa el valor base de y cuando x es neutral ($x = 0$), y h_1 representa el efecto causal que la variable x tiene sobre y , el cual es proporcional a su propio valor ($h_1 \cdot x$), dando una relación lineal entre el valor de la causa x y el valor de su efecto y .

De modo similar, podemos construir relaciones más complejas, como son los polinomios de grado M .

$$y \leftarrow h_0 + h_1 \cdot x + h_2 \cdot x^2 + \dots + h_M \cdot x^M = \sum_{i=0}^M h_i \cdot x^i$$

Es interesante notar que un polinomio de grado $M - 1$ es un caso especial de un polinomio de grado M en el que $h_M = 0$. Es decir, cuanto más complejo sea el polinomio, más flexibilidad tiene el modelo para representar la relación entre x e y .

Por conveniencia la generación de los datos observados se modelan con una distribución gaussiana, centrada en el función lineal con un ruido β . Por lo tanto, la probabilidad condicional de observar un dato a partir de uno de los polinomios es,

$$p(y|x, \mathbf{h}, \text{Modelo} = M) = \mathcal{N}\left(y \mid \sum_{i=0}^M h_i \cdot x^i, \beta^2\right)$$

Como tenemos incertidumbre respecto de los valores de las hipótesis h_i , proponemos una distribución de creencias *a priori* alrededor del cero.

$$p(h_i) = \mathcal{N}(h_i \mid 0, \alpha_i^2)$$

Luego, la especificación gráfica del modelo lineal es:




Figura 1: Modelo lineal bayesiano. Los nodos negros son constantes, los grises son variables observadas, y los blancos son hipótesis ocultas.

Herramientas sugeridas.

En este primer ejercicio vamos a comparar el comportamiento de la regresión lineal que selecciona una única hipótesis mediante máxima verosimilitud respecto del desempeño de la regresión lineal bayesiana que evalúa todo el espacio de hipótesis mediante la aplicación estricta de las reglas de la probabilidad. En el primer caso proponemos el uso del método OLS de la librería **statsmodels**, en particular los métodos `fit()` que selecciona las hipótesis (atributo `params`) y el logaritmo del likelihood del modelo (atributo `llf`). En el segundo caso proponemos la librería contenida en el archivo `ModeloLineal.py`, incluido en los materiales de esta práctica, y en particular los métodos `posterior()` que devuelve la media y la covarianza de las hipótesis y `log_evidence()` que devuelve la predicción que hace el modelo del conjunto de datos en escala logarítmica. Ambas librerías tienen un uso similar.

```
from statsmodels.api import OLS
import ModeloLineal as ml          # El archivo ModeloLineal.py debe estar en la misma carpeta
```

```

...
N = 20
X = np.random.rand(N,1)-0.5
Y = realidad_causal_subyacente(X)
assert Y.shape == (20,1)

# Transformacion de los X
def phi(X, complejidad):
    return(pd.DataFrame({'X{d}': X[:, 0]**d for d in range(complejidad+1)}))

assert phi(X, 2).shape == (20,3)

modelo = OLS(Y, phi(X,2)).fit()
modelo.params # La hipotesis seleccionadas
modelo.llf    # El likelihood del modelo en escala logaritmica

MU_2, COV_2 = ml.posterior(Y, phi(X, 2))
log_evidence_2 = ml.log_evidence(Y, phi(X, 2))

```

1.1. Generar 20 datos alrededor de un período de una sinoidal

Para poner a prueba los métodos de inferencia, vamos a generar datos de una realidad causal subyacente que los modelos polinomiales *no pueden representar exactamente*: una función sinoidal.

Supongamos que los datos se generan siguiendo una función sinoidal en el rango $x \in [-\frac{1}{2}, \frac{1}{2}]$.

$$p(x) = \text{Unif}(x | -0,5, 0,5)$$

$$p(y|x) = \mathcal{N}(y | \sin(2\pi x), \beta^2)$$

Al graficar la función objetivo (línea) y los datos (puntos) se observa lo siguiente:




Figura 2: Datos generados de la “función objetivo” (realidad causal subyacente).

Objetivo: Crear un dataset de $N = 20$ puntos (x_i, y_i) donde y sigue una sinoidal con ruido gaussiano.

1. Generá $N = 20$ valores de x uniformemente distribuidos en $[-0,5, 0,5]$. Guardá X como matriz columna de forma $(N, 1)$ para compatibilidad con las funciones que usaremos después.
2. Generá los x de la sinoidal $\sin(2\pi x_i)$ con desvío estándar $\beta = 0,2$. **Nota:** la regresión bayesiana trabaja con la *precisión*, que es el inverso de la varianza ($1/\beta^2$).
3. Graficá la curva sinoidal y los datos generados, para verificar si se parece a la figura 2. Podés usar límites verticales $[-1,5, 1,5]$ para consistencia.

1.2. Graficar el valor de máxima verosimilitud obtenido por los modelos polinomiales de grado 0 a 9

Debido a la complejidad computacional de la aplicación estricta de las reglas de la probabilidad, durante el siglo XX se propusieron una gran cantidad de criterios arbitrarios para la selección de una única hipótesis del espacio, como es el principio de máxima verosimilitud.

$$\arg \max_h p(\mathbf{y}|\mathbf{x}, \mathbf{h}, M_M) \stackrel{*}{=} \arg \min_h \sum_{j \in \{1, \dots, N\}} (y_j - \sum_i^M h_i \cdot x_j^i)^2$$

Por propiedades de este tipo de modelos (*) encontrar las hipótesis que mejor predicen es lo mismo que minimizar la suma de las distancias cuadradas entre el verdadero valor y el valor medio propuesto.

Al graficar el valor de máxima verosimilitud obtenido con cada uno de los modelos veremos que a medida que aumentamos la complejidad de los modelos aumenta también el valor de máxima verosimilitud.




Figura 3: Máxima verosimilitud en función de la complejidad del modelo.

Esto ocurre debido a que cuanto más flexible es un modelo, más se puede acercar a todos los puntos. Por lo tanto, si usamos el criterio de máxima verosimilitud para seleccionar modelo, elegiríamos siempre el modelo más complejo.

Objetivo: Ajustar modelos polinomiales de grado 0 a 9 por máxima verosimilitud (OLS) y graficar cómo crece el likelihood con la complejidad.

1. Implementaré una función de transformación polinómica $\phi(x, M)$ que, dado un vector x y un grado M , devuelva una matriz donde cada columna sea una potencia de x : desde $x^0 = 1$ (columna de unos, el intercepto) hasta x^M . Es decir, para grado M la matriz tendrá $M + 1$ columnas.
2. Para cada grado de 0 a 9, transformaré los datos de entrada y ajustaré el modelo usando OLS.
3. Extraeré la verosimilitud de cada modelo (atributo `llf` del modelo ajustado, que está en escala logarítmica).
4. Graficaré la verosimilitud (exponenciada si querés escala lineal) en función del grado del polinomio.

Checkeos rápidos.

- La verosimilitud crece monótonamente con el grado del polinomio.
- El modelo de grado 9 tiene la mayor verosimilitud de todos.
- La matriz de transformación para grado M tiene $M + 1$ columnas.

1.3. Graficar las curvas obtenidas con cada modelo mediante máxima verosimilitud

Seleccionar el modelo de mayor complejidad no es deseable. Para ver por qué, vamos a graficar las curvas obtenidas por cada uno de los modelos de grado 0 a 9.




Figura 4: Ajuste de los polinomios por máxima verosimilitud.

En la figura 4a podemos ver que los modelos de grado 0 a 2 no tienen la complejidad suficiente para acercarse a los datos como lo hacen los modelos de complejidad 3 o superior. En la figura 4b destacamos la curva que se obtiene con el modelo más complejo, de grado 9.

A diferencia del modelo 3 (color rojo en figura 4a) que se mantiene cerca de la función objetivo, el modelo de grado 9 se separa significativamente de la función objetivo alrededor de los valores $x = 0,3$ y $x = 0,5$. La excesiva flexibilidad hace que los modelos más complejos adopten formas extrañas que suelen alejarse más de la función objetivo oculta, por lo que la predicción sobre nuevos datos del modelo 3 termina siendo superior al del modelo 9 que habíamos elegido por máxima verosimilitud.

Esto se conoce en el área de inteligencia artificial con el nombre de **sobreajuste** o *overfitting* y veremos que es un efecto secundario de utilizar métodos arbitrarios de selección de hipótesis (como máxima verosimilitud) y no una propiedad indeseable del sistema de razonamiento probabilístico.

Objetivo: visualizar el overfitting. Graficar las curvas ajustadas por OLS para cada modelo y observar el fenómeno de sobreajuste.

1. Creá una grilla fina de valores de x en el rango $[-0,5; 0,5]$,
2. Para cada modelo de 0 a 9, usá sus propios parámetros h_i para obtener los y para cada x de la grilla.
3. Graficá todas las curvas junto con los datos observados, como en la figura 4a.
4. Graficá solo el modelo de grado 9 junto con la función objetivo $\sin(2\pi x)$, como en la figura 4b. Podés usar límites verticales consistentes $([-1,5, 1,5])$.

Checkeos rápidos.

- Los modelos de grado 0, 1, 2 son líneas/curvas suaves que no capturan la forma sinoidal.
- El modelo de grado 3 sigue razonablemente bien la sinoidal.
- El modelo de grado 9 hace “piruetas” especialmente en la región entre $x = 0,2$ y $x = 0,4$.

1.4. Evaluación de la predicción “en línea” que hacen los modelos ajustados por máxima verosimilitud

Para evaluar correctamente los modelos alternativos deberíamos calcular la evidencia de los modelos, $P(\text{Datos}|\text{Modelo})$, que no es más que la predicción conjunta *a priori* que hace el modelo de todos los datos. Sabemos que la predicción conjunta se puede descomponer como el producto de las predicciones individuales del siguiente dato usando los datos ya observados previamente.

$$P(\text{Datos} = \{d_1, d_2, \dots\} | M_D) = P(d_1 | M_D) P(d_2 | d_1, M_D) \dots$$

Este producto de predicciones representa lo que nos ocurriría efectivamente si usáramos el modelo en la vida real: ajustamos el modelo con los datos que ya tenemos disponibles (entrenamiento) y evaluamos el desempeño en los datos nuevos (testeo). Para simular este proceso, vamos a implementar un procedimiento en el cual predecimos los datos individuales ajustando los modelos por máxima verosimilitud sobre los datos observados previamente.




Figura 5: Producto de las predicciones *a priori* de los modelos ajustados por máxima verosimilitud.

Si evaluáramos los modelos en base al desempeño predictivo, dado por el producto de las predicciones *a priori*, rechazaríamos todos los modelos salvo el de grado 3. Esto también es un caso de sobreajuste (overfitting), pues en caso de recibir datos por fuera del período, tendríamos bajo desempeño predictivo debido a que el modelo de grado 3 no tendrá la flexibilidad suficiente para acercarse a la función objetivo.

El problema del sobreajuste (overfitting) ocurre como efecto secundario de seleccionar una única hipótesis del espacio y no poder computar de forma exacta la evidencia de los modelos, $P(\text{Datos}|\text{Modelo})$. Cuando seleccionamos de forma arbitraria una única hipótesis no podemos computar la evidencia de los modelos, $P(\text{Datos}|\text{Modelo})$, debido a que las predicciones que hacen los modelos deberían realizarse con la contribución de *todas* las hipótesis, y no con una única hipótesis seleccionada previamente.

$$P(y_i | \underbrace{x_1, y_1, \dots, x_{i-1}, y_{i-1}}_{d_1}, x_i, M_D) = \int_{\mathbf{h}} P(y_i | d_1, \dots, d_{i-1}, x_i, \mathbf{h}, M_D) P(\mathbf{h} | d_1, \dots, d_{i-1}, M_D) \\ \approx P(y_i | d_1, \dots, d_{i-1}, x_i, \underbrace{\arg \max_{\mathbf{h}} P(d_1, \dots, d_{i-1} | \mathbf{h}, M_D)}_{\text{Hipótesis de máxima verosimilitud}}, M_D)$$

Es decir, aproximamos las predicciones que deberían hacer los modelos con la contribución de todas las hipótesis mediante la predicción que obtenemos con la hipótesis que maximizaba la verosimilitud en el paso anterior.

Objetivo: evaluación predictiva “en línea”. Calcular el producto de predicciones secuenciales para cada modelo, simulando el uso “en la vida real”.

1. Inicializá cada modelo ajustándolo con el primer dato solamente. Esto te da un punto de partida para empezar a predecir.
2. Para cada grado de 0 a 9, inicializá la log-verosimilitud acumulada en 0 (trabajar en escala log evita underflow).
3. Para cada dato i desde 1 hasta $N - 1$, en este orden:
 - a) Primero predecí: usá el modelo *actual* (entrenado con datos 0 a $i - 1$) para predecir y_i dado x_i .
 - b) Evaluá: calculá la log-probabilidad de observar el verdadero y_i bajo una gaussiana $\mathcal{N}(\hat{y}_i, \beta^2)$ donde $\hat{y}_i$ es tu predicción.
 - c) Sumá esta log-verosimilitud al acumulado.
 - d) Finalmente re-entrená: actualizá el modelo incluyendo ahora el dato i (datos 0 a i).
4. Graficá la verosimilitud acumulada, replicando la figura 5. Antes de exponenciar las log-verosimilitudes conviene restale a todas el valor máximo de entre ellas (para evitar el underflow justamente).

Checkeos rápidos.

- El modelo de grado 3 tiene la mayor verosimilitud predictiva (¡no el de grado 9!).
- Los modelos de grado 0, 1, 2 tienen verosimilitud predictiva muy baja.
- Los modelos de grado alto (7, 8, 9) tienen peor desempeño que el de grado 3.

1.5. El balance natural de las reglas de la probabilidad

Para evaluar correctamente las hipótesis y modelos causales alternativos es suficiente con actualizar las creencias aplicando estrictamente las reglas de la probabilidad. Para eso necesitamos calcular la probabilidad *a posteriori* de los modelos dado los datos.

$$P(\text{Modelo} = m | \text{Datos}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo} = m)}^{\text{Evidencia}} P(\text{Modelo} = m)}{\sum_i P(\text{Datos} | \text{Modelo} = i) P(\text{Modelo} = i)}$$

Para calcular de forma exacta la evidencia del modelo (en órdenes de magnitud) podemos usar el método `ml.log_evidence()` de nuestro paquete `ModeloLineal.py`. Suponiendo que no tenemos preferencia *a priori* por ningún modelo, vamos a usar la evidencia para calcular el posterior exacto de los modelos.




Figura 6: Posterior exacto de los modelos usando inferencia bayesiana.

Cuando evaluamos correctamente las hipótesis, encontramos que:

- El modelo que tiene la menor complejidad necesaria (grado 3) es el que obtiene mayor creencia *a posteriori*.

- Los modelos que tienen menor complejidad de la necesaria (grado 0 a 2) son rechazados.
- Los modelos que tienen mayor complejidad de la necesaria (grado 4 a 9) tienen baja probabilidad, pero no son rechazados.

A diferencia de lo que ocurría cuando seleccionábamos hipótesis de forma arbitraria, evaluando correctamente las hipótesis garantizamos nuestra capacidad para predecir potenciales datos que aparecieran en el futuro por fuera del período observado gracias a que tenemos disponibles todavía modelos más complejos capaces de explicarlos.

$$P(\text{Datos}) = \sum_m P(\text{Datos}|\text{Modelo} = m)P(\text{Modelo} = m)$$

En definitiva, los problemas que emergen cuando se seleccionan las hipótesis mediante criterios arbitrarios simplemente no forman parte del sistema de razonamiento en contextos de incertidumbre. Por eso, la aplicación estricta de las reglas de la probabilidad, siguiendo el principio de “no mentir”, es el razonamiento óptimo en contextos de incertidumbre.

Objetivo: posterior bayesiano de modelos. Calcular el posterior exacto $P(M|\text{Datos})$ para modelos de grado 0 a 9 usando la evidencia bayesiana.

1. Para cada grado de 0 a 9, calculá la log-evidencia usando la función `log_evidence` del módulo `ModeloLineal.py`. Nota: esta función devuelve un tipo de datos matriz aunque sea solo un escalar. Extraer el escalar.
2. Definí un prior uniforme sobre los 10 modelos.
3. Calculá el posterior no normalizado: $P(M|\text{Datos}) \propto P(\text{Datos}|M) \cdot P(M)$.
4. Normalizá dividiendo por la suma para que el posterior sume 1.
5. Graficá el posterior en función del grado del polinomio.

Checkeos rápidos.

- El posterior suma exactamente 1.
- El modelo de grado 3 tiene la barra más alta.
- Los modelos de grado 4 a 9 tienen barras pequeñas pero visibles (no son cero).
- Los modelos de grado 0, 1, 2 tienen barras prácticamente invisibles.

1.6. Cómo se explica el balance natural de las reglas de la probabilidad

En probabilidad las predicciones son distribuciones de probabilidad que deben integrar 1. Esto produce un balance natural entre los modelos debido a que ningún modelo es superior a otro en términos absolutos. Todos los modelos tienen una región en donde ganan y todos tienen una región en donde pierden. Veamos esto de forma concreta.

En la figura 7a graficamos la media del posterior de los modelos basado en un prior no informativo. No estamos graficando la incertidumbre de los modelos, que representaría la predicción que hacen los modelos de los datos. Para graficar esa incertidumbre vamos a hacer un corte en la figura 7a cuando x vale $-0,23$ (línea vertical).




Figura 7: El balance natural entre modelos.

En la figura 7b hacemos un corte en la línea punteada ($x = -0.23$) y graficamos la predicción que hace el modelo más rígido (grado 0), el modelo simple (grado 3) y el modelo más complejo (grado 9) luego de ver el cuarto dato. Observamos tres distribuciones gaussianas con diferente media y diferente desvío estándar.

Podemos ver que:

- El modelo más rígido (grado 0) concentra su creencia en una región lejana al valor verdadero.
- Los modelos simple (grado 3) y complejo (grado 9) distribuyen su creencia alrededor del verdadero valor pero de forma distinta: cuanto mayor flexibilidad tienen los modelos, mayor tendencia a distribuir la creencia en una región más amplia de valores posibles.

En términos un poco más esquemáticos (con $x = 0.1$) lo que ocurre es:




Figura 8: Esquema de la predicción de los modelos: el área bajo cada curva debe ser 1.

De esta forma:

- El modelo rígido se rechaza por su incapacidad de llevar su creencia a la región correcta.
- Entre el modelo simple y el modelo complejo hay un balance en el cual existen ciertas regiones donde el modelo simple gana y ciertas regiones donde el modelo más complejo gana.

Objetivo: visualizar el balance. Graficar la predicción (distribución gaussiana) que hacen distintos modelos en un punto fijo x^* y entender el trade-off flexibilidad vs. precisión.

1. Primero graficé la media del posterior para todos los modelos usando la función `posterior()` de `ModeloLineal.py`, que devuelve medias y covarianzas de las hipótesis. Usé un prior poco informativo (α pequeño).

2. Elegí un punto de corte (por ejemplo, $x^* = -0,23$) y agregá una línea vertical en el gráfico anterior.
3. Para visualizar el balance, usá solo los primeros datos (por ejemplo, 4) para que la incertidumbre sea apreciable. Para los modelos de grado 0 (rígido), 3 (simple) y 9 (complejo):
 - a) Calculá la distribución predictiva en x^* . Podés usar `ml.predictive()` directamente, o calcularla manualmente: la media es $\phi(x^*)^T \mu$ y la varianza es $\phi(x^*)^T \Sigma \phi(x^*)$.
 - b) Graficá la distribución gaussiana resultante para cada modelo.
4. Observá cómo la altura de cada gaussiana en el valor verdadero determina cuánto “gana” ese modelo.

Checkeos rápidos.

- El modelo de grado 0 (“Rígido”) tiene una gaussiana angosta pero centrada lejos del valor verdadero.
- El modelo de grado 9 (“Complejo”) tiene una gaussiana más ancha, centrada cerca del valor verdadero.
- El modelo de grado 3 (“Simple”) tiene un buen balance: centrado y no demasiado disperso.

2. Efecto causal del sexo biológico sobre la altura.

Vamos a utilizar un conjunto de datos sobre alturas de un grupo de personas y 3 variables adicionales: sexo biológico, contextura de la madre, y altura de la madre. En este ejemplo vamos a proponer modelos causales alternativos entre estas variables.

2.1. Abrir el archivo `alturas.csv` y visualizar los datos

El archivo de datos tiene la siguiente estructura,.

	id	altura	sexo	contextura_madre	altura_madre
0	1	172.7	M	mediana	159.8
1	2	171.5	M	mediana	160.3
2	3	162.6	F	mediana	160.5
3	4	174.1	M	mediana	159.8
4	5	168.3	M	mediana	158.3

En la siguiente figura graficamos la altura en función de la altura de la madre, y coloreamos los puntos en función del sexo.




Figura 9: Datos de alturas

Si bien los datos son de dudosa procedencia, vamos a jugar un juego de inferencia causal. Vamos a proponer y evaluar tres modelos causales alternativos.

2.2. Definir 3 modelos causales alternativos

En el modelo base vamos a suponer que la altura de la madre tienen un efecto causal lineal sobre la altura de su descendencia.

$$\text{Modelo Base: } \text{altura} = h_0 + h_1 \cdot \text{altura_madre}$$

En el modelo biológico vamos a suponer que el sexo tiene un efecto causal adicional sobre la altura.

$$\text{Modelo Biológico: } \text{altura} = h_0 + h_1 \cdot \text{altura_madre} + h_2 \cdot \mathbb{I}(\text{sexo} = F)$$

Cuando el sexo es masculino, la función identidad $\mathbb{I}(\text{sexo} = M)$ vale 1 y en caso contrario vale 0, lo que prende y apaga la hipótesis h_2 , que representa el efecto causal adicional del sexo biológico.

Por último vamos a plantear el modelo identitario, en el que vamos a suponer que la identidad de la persona (y no el sexo) tiene efecto causal sobre la altura.

$$\text{Modelo grupos al azar: } \text{altura} = h_0 \cdot \text{altura_madre} + h_{1+(\text{ID} \bmod (\max(\text{ID})/2))}$$

Notar que los grupos al azar son todos de tamaño 2 y que cada grupo tiene su propia ordenada al origen pero comparten la misma pendiente. Es decir, cuando queramos usar `OLS(Y,phi)` o `log_evidence(Y,phi)`, el `phi` va a ser una matriz con 26 columnas: la primera con la altura de la madre y las siguientes 25 columnas con 0 y 1, indicando quién pertenece a un determinado grupo.

2.3. Computar la evidencia de los modelos causales alternativos

En la siguiente figura graficamos los órdenes de magnitud de evidencia ($P(\text{Datos}|\text{Modelo})$) de los 3 modelos causales alternativos.




Figura 10: Evidencia en escala logarítmica de los modelos causales alternativos

Interpretación: ¿Qué nos dice el gráfico?.

2.4. Computar la media geométrica de los modelos causales alternativos

La media geométrica

$$P(\text{Datos} = \{d_1, d_2, \dots, d_N\} | M) = P(d_1 | M) P(d_2 | d_1, M) \dots = \prod_{i \in \{1, \dots, N\}} \underbrace{(P(d_1 | M) P(d_2 | d_1, M) \dots)^{1/N}}_{\text{Media geométrica}}$$

- Tenés el Log-Evidence total ($\ln P(D|M)$).
- Tenés la cantidad de datos N (ej: 200 personas).
- La fórmula es deshacer el logaritmo y promediar:

$$\text{Media geométrica} = \exp \left(\frac{\text{LogEvidence}}{N} \right)$$

2.5. Computar el posterior de los modelos

$$P(\text{Modelo}|\text{Datos}) = \frac{P(\text{Datos}|\text{Modelo})P(\text{Modelo})}{P(\text{Datos})}$$

1. Encontrá el valor máximo de tus log-evidencias: $L_{max} = \max(L_1, L_2, L_3)$.
2. Restale ese máximo a todos: $L'_i = L_i - L_{max}$. (El máximo ahora valdrá 0, y el resto serán negativos chicos).
3. Ahora sí, exponenciá: $\text{scores}_i = \exp(L'_i)$.
4. Normalizá: $P(M_i|D) = \frac{\text{scores}_i}{\sum \text{scores}}$.