




Belief propagation

Inferencia exacta. El algoritmo de eliminación de variables. Descomposición de las reglas de la probabilidad como mensajes que se envían entre sí los nodos de las redes causales: algoritmo suma-producto. El caso del modelo Monty Hall extendido. Distribuciones conjugadas. Modelo Beta-Bernoulli y sus aplicaciones en medicina y marketing. Modelo gaussianos unidimensionales y la solución exacta al modelo de estimación de habilidad. Modelo gaussianos multidimensionales: posterior y evidencia. Regresión lineal bayesiana. Selección arbitraria de hipótesis mediante máxima verosimilitud. Interpretación de los parámetros estimados bajo realidades causales conocidas. Evaluación de modelos lineales de complejidad creciente. La ausencia de overfitting mediante la aplicación estricta de las reglas de la probabilidad. Predicción basada en ensambles de modelos, $P(\text{Datos})$.

Bibliografía Unidad 2.1

- Koller 2009. *Probabilistic Graphical Models* ([Descargar](#)). **Lectura: cap 9 y 10.**
- Bishop 2006. *Pattern Recognition and Machine Learning*. **Lectura: cap 3 (y 2).**
- Winn 2023. *Model-Based Machine Learning*. ([Descargar](#)). **Lectura: cap 1 y 2.**

Otras:

- Kschischang FR, Frey BJ, Loeliger HA. Factor graphs and the sum-product algorithm. 2001

El costo computacional

Problema histórico de la probabilidad

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).
- Siglo 21: Comienza a ser posible evaluar todo el espacio de hipótesis mediante la (aproximación a) la aplicación estricta de las reglas de la probabilidad de forma general

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones.

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos las posibles combinaciones de valores de verdad.

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos las posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

$$1: P(a, b, \dots, z) = \dots$$

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos las posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

1: $P(a, b, \dots, z) = \dots$

2: $P(\neg a, b, \dots, z) = \dots$

El costo computacional

Problema histórico de la probabilidad

Tenemos $n = 27$ variables, las letras del alfabeto

- En lógica binaria asignamos valores a las variables, y con las reglas de la lógica calculamos las combinaciones. Con 27 bits nos alcanza.
- En lógica extendida debemos asignar una probabilidad a cada posible combinación de todos las posibles combinaciones de valores de verdad.

Necesitamos guardar $2^{27} - 1$ números reales

$$1: P(a, b, \dots, z) = \dots$$

$$2: P(\neg a, b, \dots, z) = \dots$$

$$\vdots \dots$$

$$2^{27}: (\neg a, \neg b, \dots, \neg z) = 1 - \sum_i^{2^{27}-1} P(\dots)$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) =$$

Redes Bayesianas


Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$

Redes Bayesianas

Menor complejidad computacional


$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) =$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a \sum_c \dots \sum_y \sum_z P(a, b, \dots, y, z)$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a \sum_c \dots \sum_y \sum_z P(a) P(b|a) \dots P(y|x) P(z|y)$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_{\color{red}a} \sum_c \dots \sum_y \sum_z P(a) P(b|a) \dots P(y|x) P(z|y)$$


Una vez entramos en el ciclo de a

.

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_{\color{red}a} \sum_c \dots \sum_y \sum_z \color{red}P(a) P(b|a) \dots P(y|x) P(z|y)$$

Una vez entramos en el ciclo de a , $P(a)$ queda fijo (factor común).

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_{\textcolor{red}{a}} \textcolor{red}{P(a)} \sum_c \dots \sum_y \sum_z P(b|a) \dots P(y|x) P(z|y)$$

Una vez entramos en el ciclo de a , $P(a)$ queda fijo (factor común).

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a P(a) \sum_c \dots \sum_y \sum_z P(b|a) \dots P(y|x) P(z|y)$$

Sacar factores comunes es una operación clave

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a P(a) P(b|a) \sum_c \dots \sum_y P(y|x) \sum_z P(z|y)$$

Sacar factores comunes es una operación clave

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a) \sum_c \dots \sum_y P(y|x) \sum_z P(z|y)$$


Sacar factores comunes es una operación clave

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a) \sum_c \dots \sum_y P(y|x)$$


Sacar factores comunes es una operación clave

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a) \sum_c \dots \sum_y \cancel{P(y|x)}$$


Sacar factores comunes es una operación clave

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a) \sum_c \dots$$


Sacar factores comunes es una operación clave

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a)P(b|a)$$


Sacar factores comunes es una operación clave

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a)P(b|a)$$


Sacar factores comunes es una operación clave

Pudimos computar una marginal sin generar la conjunta!

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a P(a) P(b|a)$$

$$P(z) = \sum_a \sum_b \dots \sum_x \sum_y P(a, b, \dots, y, z)$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$




$$P(b) = \sum_a P(a)P(b|a)$$

$$P(z) = \sum_a \sum_b \dots \sum_x \sum_y P(a)P(b|a)P(c|b) \dots P(y|x)P(z|y)$$

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a)P(b|a)$$


$$P(z) = \sum_a \sum_b \dots \sum_x \sum_y P(a)P(b|a)P(c|b) \dots P(y|x)P(z|y)$$

Las productos y las sumatorias son conmutativas

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_a \sum_b \dots \sum_x \sum_y P(z|y) P(y|x) \dots P(c|b) P(b|a) P(a)$$

Las productos y las sumatorias son conmutativas

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a)P(b|a)$$


$$P(z) = \sum_y \sum_x \dots \sum_b \sum_a P(z|y)P(y|x) \dots P(c|b)P(b|a)P(a)$$

Las productos y las sumatorias son conmutativas

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y \sum_x \dots \sum_b P(z|y) P(y|x) \dots P(c|b) \sum_a P(b|a) P(a)$$

Las productos y las sumatorias son conmutativas

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \sum_x P(y|x) \dots \sum_b P(c|b) \sum_a P(b|a) P(a)$$

Las productos y las sumatorias son conmutativas

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \sum_x P(y|x) \dots \sum_b P(c|b) \left(\sum_a P(b|a) P(a) \right)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \sum_x P(y|x) \dots \sum_b P(c|b) \left(P(b) \right)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \sum_x P(y|x) \dots \left(\sum_b P(c|b) P(b) \right)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \sum_x P(y|x) \dots \left(P(c) \right)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) \left(\sum_x P(y|x) P(x) \right)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a) P(b|a)$$


$$P(z) = \sum_y P(z|y) P(y)$$

Programación dinámica: invertir el orden, computamos de adentro hacia afuera

Redes Bayesianas

Menor complejidad computacional

$$P(a, b, \dots, y, z) = P(a) P(b|a) \dots P(y|x) P(z|y)$$



$$P(b) = \sum_a P(a)P(b|a)$$

$$P(z) = \sum_y P(z|y)P(y)$$

Pudimos computar una marginal sin generar la conjunta!

Redes Bayesianas

Menor complejidad computacional

Dado que el alcance (scope) de los factores es limitado, **la clave es**, “introducir” algunas sumatorias para ejecutarlas sobre el producto de un subconjunto de factores

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```

```
eliminar-variable( $\Phi, Z$ )
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```

```
eliminar-variable( $\Phi, Z$ )  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```

```
eliminar-variable( $\Phi, Z$ )  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```


```
eliminar-variable( $\Phi, Z$ )  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```


```
eliminar-variable( $\Phi, Z$ )  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```



Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$  // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```




$$\Phi = \{P(x), P(a|x)P(b|a), P(c|b, x)\}$$

```
eliminar-variable( $\Phi, Z$ )  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```




$$\Phi = \{P(x), P(a|x)P(b|a), P(c|b, x)\}$$
$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
 $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
 $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(x), P(a|x)P(b|a), P(c|b, x)\}$$

$$Z = [C, X, A]$$


```
eliminar-variable( $\Phi, Z$ )  
  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```

$$\psi_c = \sum_c P(c|b, x)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(x), P(a|x)P(b|a), P(c|b, x)\}$$

$$Z = [C, X, A]$$


```
eliminar-variable( $\Phi, Z$ )  
  
 $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
 $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```

$$\psi_c = \sum_c P(c|b, x) = 1$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(x), P(a|x)P(b|a), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```


$$\psi_c = \sum_c P(c|b, x) = 1$$

$$\psi_x = \sum_x P(x)P(a|x)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$  // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(x), P(a|x)P(b|a), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```


$$\psi_c = \sum_c P(c|b, x) = 1$$

$$\psi_x = \sum_x P(x)P(a|x) = P(a)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(a), P(b|a), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
 $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
 $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```


$$\psi_c = \sum_c P(c|b, x) = 1$$

$$\psi_x = \sum_x P(x)P(a|x) = P(a)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$     // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
for i in 1:len( $Z$ )  
   $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(a), P(b|a), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
 $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
 $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
return  $(\Phi - \Phi') \cup \psi$ 
```

$$\psi_c = \sum_c P(c|b, x) = 1$$


$$\psi_x = \sum_x P(x)P(a|x) = P(a)$$

$$\psi_a = \sum_a P(a)P(b|a)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$  // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(a), P(b|a), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```

$$\psi_c = \sum_c P(c|b, x) = 1$$


$$\psi_x = \sum_x P(x)P(a|x) = P(a)$$

$$\psi_a = \sum_a P(a)P(b|a) = P(b)$$

Redes Bayesianas

Sum-product variable elimination algorithm

```
sum-product-VE(  
   $\Phi$  // Conjunto de factores  
   $Z$  ) // Variables a ser eliminadas  
  
  for i in 1:len( $Z$ )  
     $\Phi \leftarrow \text{eliminar-variable}(\Phi, Z_i)$   
  return  $\prod_{\phi}^{\Phi} \phi$ 
```



$$\Phi = \{P(b), 1\}$$

$$Z = [C, X, A]$$

```
eliminar-variable( $\Phi, Z$ )  
  
   $\Phi' \leftarrow \{\phi \in \Phi : Z \in \text{scope}(\phi)\}$   
   $\psi \leftarrow \sum_z \left( \prod_{\phi}^{\Phi'} \phi \right)$   
  return  $(\Phi - \Phi') \cup \psi$ 
```


$$\psi_c = \sum_c P(c|b, x) = 1$$

$$\psi_x = \sum_x P(x)P(a|x) = P(a)$$

$$\psi_a = \sum_a P(a)P(b|a) = P(b)$$


Sum-product variable elimination algorithm

Factores intermedios



Sum-product variable elimination algorithm


Factores intermedios



No todos los factores intermedios son marginales o condicionales del modelo

Sum-product variable elimination algorithm

Factores intermedios




$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

Sum-product variable elimination algorithm

Factores intermedios




$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x P(x)P(a|x)P(c|b, x)$$

Sum-product variable elimination algorithm

Factores intermedios




$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_?$$

Sum-product variable elimination algorithm

Factores intermedios




$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\text{¿}P(x, a, c|b)\text{?}}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$


$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\text{¿}P(x, a, c|b)\text{?}}$$

$$P(x, a, c|b) = \frac{P(x, a, b, c)}{P(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$


$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\text{¿}P(x, a, c|b)\text{?}}$$

$$P(x, a, c|b) = \frac{P(x)P(a|x)P(b|a)P(c|b, x)}{P(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$


$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\text{¿}P(x, a, c|b)\text{?}}$$

$$P(x, a, c|b) = P(x)P(a|x)P(c|b, x) \frac{P(b|a)}{P(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$


$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

$$P(x, a, c|b) = P(x)P(a|x)P(c|b, x) \frac{P(b|a)}{P(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$



$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

Conocer el valor de b cambia nuestra creencia sobre a
(hay flujo de inferencia, a no es independiente de b)

Sum-product variable elimination algorithm

Factores intermedios





$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

Sum-product variable elimination algorithm

Factores intermedios





$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$



$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

$$P'(x, a, c|b) = \frac{P'(x, a, b, c)}{P'(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$



$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

$$P'(x, a, c|b) = \frac{P'(x)P'(a|x)P'(b)P'(c|b, x)}{P'(b)}$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$



$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{\cancel{P(x, a, c|b)}}$$

$$P'(x, a, c|b) = P'(x)P'(a|x)P'(c|b, x)$$

Sum-product variable elimination algorithm

Factores intermedios



$$\Phi = \{P(x), P(a|x), P(b|a), P(c|b, x)\}$$

$$\mathbf{Z} = [X]$$

$$\psi = \sum_x \underbrace{P(x)P(a|x)P(c|b, x)}_{P'(x, a, c|b)}$$

$$P'(x, a, c|b) = P'(x)P'(a|x)P'(c|b, x)$$

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$


$$P(v) =$$

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$




¿Sobre cuáles factores puedo aplicar una sumatoria?

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$



¿Sobre cuáles factores puedo aplicar una sumatoria?


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$

$$\sum_u \sum_w \sum_x$$



¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$

$$\sum_u \sum_w \sum_x$$



¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$

$$\sum_w \sum_x$$



¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$

$$\sum_w \sum_x$$



¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$

$$\begin{array}{ccc} x & \sum_w \sum_x & 1 \\ & P(x) & \\ & P(v|w, x) - v & \\ w & P(w) & 1 \end{array}$$


¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) =$$




¿Qué combinación simple de factores puedo agrupar para aplicar una sumatoria?

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) = P(v) \cdot 1 \cdot 1$$



El producto de factores remanentes computa la marginal


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) = P(v) \cdot 1 \cdot 1$$

$$P(v, z) = ?$$



El producto de factores remanentes computa la marginal


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) = P(v) \cdot 1 \cdot 1$$

$$P(v, z) = ?$$



El producto de factores remanentes computa la marginal

Para $P(v, z)$ no hubiéramos sumado en z


Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v) = P(v) \cdot 1 \cdot 1$$

$$P(v, z) = P(z|v)P(v)$$




El producto de factores remanentes computa la marginal

Para $P(v, z)$ no hubiéramos sumado en z

Sum-product algorithm

Pasaje de mensajes


Algoritmo para calcular cualquier marginal mediante pasaje de mensajes entre nodos



Sum-product algorithm

Pasaje de mensajes

Algoritmo para calcular cualquier marginal mediante pasaje de mensajes entre nodos




$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

Sum-product algorithm

Pasaje de mensajes

Algoritmo para calcular cualquier marginal mediante pasaje de mensajes entre nodos



$v(n)$: Vecinos del nodo n

$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

Sum-product algorithm


Pasaje de mensajes

$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n


$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x



Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n


$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n


$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n

$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f


$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h)$$

Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n

$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f


$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h)$$

Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n

$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f


$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left(f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$

Sum-product algorithm

Pasaje de mensajes



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$: Vecinos del nodo n

$m_{x \rightarrow f}(x)$: Mensaje de variable x a factor f

$m_{f \rightarrow x}(x)$: Mensaje de factor f a variable x

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$


$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left(f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$

Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura

$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) =$$




Sum-product algorithm

Aprovechando la estructura


$$P(u, v, w, x, y, z) = P(u)P(w|u)P(x)P(v|w, x)P(y|v)P(z|v)$$

$$P(v, z) = P(v) \cdot P(z|v) \cdot 1$$




Mecanismos causales dinámicos

Gates




Mecanismos causales dinámicos

Gates




Mecanismos causales dinámicos

Gates



Mecanismos causales dinámicos


Gates



$$P(s_t|r_t, c_t, a_t) = P(s_t|r_t)^{\mathbb{I}(a_t=0)} P(s_t|r_t, c_t)^{\mathbb{I}(a_t=1)}$$


Inferencia eficiente

Todas las variables ocultas




Inferencia eficiente

Todas las variables observadas




Inferencia eficiente




Recordar que las variables conocidas (observadas) están fijas (no se integran).

Inferencia eficiente



En este caso se van a ir acumulando el producto de distribuciones condicionales.


Inferencia eficiente



En este caso se van a ir acumulando el producto de distribuciones condicionales. El producto de mensajes que llegan a una variable será la distribución conjunta.


Inferencia eficiente

estructuras causales dinámicas



Inferencia eficiente

estructuras causales dinámicas




$$m_{f_r \rightarrow r}(r) =$$

$$m_{f_p \rightarrow p}(p) =$$

$$m_{f_c \rightarrow c}(c) =$$

Inferencia eficiente

estructuras causales dinámicas




$$m_{f_r \rightarrow r}(r) = P(r)$$

$$m_{f_p \rightarrow p}(p) = P(p)$$

$$m_{f_c \rightarrow c}(c) = P(c)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_s \rightarrow a}(a) =$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_s \rightarrow a}(a) = P(r)P(c)P(s|r)^{\mathbb{I}(a=0)}P(s|r, c)^{\mathbb{I}(a=1)}$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_s \rightarrow a}(a) = P(r)P(c)P(s|r)^{\mathbb{I}(a=0)}P(s|r, c)^{\mathbb{I}(a=1)} = P(r, c, s|a)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_a \rightarrow p}(p) =$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_a \rightarrow p}(p) = \sum_a P(r, c, s|a)P(a|p)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_a \rightarrow p}(p) = \sum_a P(r, c, s|a)P(a|p) = P(r, c, s|p)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{p \rightarrow f_{a_{T+1}}}(p) =$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{p \rightarrow f_{a_{T+1}}}(p) = P(p) \prod_{i=1}^T P(r_i, c_i, s_i | p)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{p \rightarrow f_{a_{T+1}}}(p) = P(p) \prod_{i=1}^T P(r_i, c_i, s_i | p) = P(r_1, c_1, \dots, c_T, s_T, p)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_{a_3 \rightarrow a_3}}(a_3) =$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_{a_3 \rightarrow a_3}}(a_3) = \sum_p P(a_3|p) P(r_1, c_1, s_1, r_2, c_2, s_2, p)$$

Inferencia eficiente


estructuras causales dinámicas



$$m_{f_{a_3 \rightarrow a_3}}(a_3) = \sum_p P(a_3|p)P(r_1, c_1, s_1, r_2, c_2, s_2, p) = P(r_1, \dots, s_2, a)$$

Inferencia eficiente


estructuras causales dinámicas



$$P(a_3 | \overbrace{r_1, \dots, s_3}^{\text{Datos}}) \propto$$

Inferencia eficiente


estructuras causales dinámicas



$$P(a_3 | \overbrace{r_1, \dots, s_3}^{\text{Datos}}) \propto P(r_1, c_1, s_1, r_2, c_2, s_2, a_3) P(r_3, c_3, s_3 | a_3)$$


Inferencia eficiente

estructuras causales dinámicas



Inferencia eficiente

estructuras causales dinámicas



$$P(p1, \overbrace{r_1, \dots, s_3}^{\text{Datos}}) = P(p) \prod_{i=1}^T P(r_i, c_i, s_i | p)$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p)$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3}\frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3}\frac{1}{3}\frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3}\frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3}\frac{1}{3}\frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$. Quizás no se olvidó.

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3} \frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3} \frac{1}{3} \frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$. Quizás no se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 1$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3}\frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3}\frac{1}{3}\frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$. Quizás no se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 1 \implies P(r, c, s|p) = (1+p)/18$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3}\frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3}\frac{1}{3}\frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$. Quizás no se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 1 \implies P(r, c, s|p) = (1+p)/18$$

$$\prod_{t=1}^T P(r_t, c_t, s_t|p) =$$

Analizando el likelihood

$$P(r, c, s|p) = \sum_a P(r)P(c)P(s|r, c, a)P(a|p) = \underbrace{P(r)P(c)}_{\frac{1}{3}\frac{1}{3}} \left(P(s|r)(1-p) + P(s|r, c)p \right)$$

Caso 0: $r = c$. No podemos saber si se olvidó o se acordó.

$$P(s|r) = P(s|r, c) = 1/2 \implies P(r, c, s|p) = \frac{1}{3}\frac{1}{3}\frac{1}{2} = 1/18$$

Caso 1: $r \neq c$ y $c = s$. Seguro se olvidó.


$$P(s|r) = 1/2, P(s|r, c) = 0 \implies P(r, c, s|p) = (1-p)/18$$

Caso 2: $r \neq c$ y $c \neq s$. Quizás no se olvidó.

$$P(s|r) = 1/2, P(s|r, c) = 1 \implies P(r, c, s|p) = (1+p)/18$$


$$\prod_{t=1}^T P(r_t, c_t, s_t|p) = \frac{1}{18} \left(1^{n_0} (1-p)^{n_1} p^{n_2} \right)$$

Analizando el likelihood




Inferencia eficiente

Los modelos como variable




Inferencia eficiente

Los modelos como variable




Inferencia eficiente

Los modelos como variable




Los modelos como variable



Inferencia eficiente


Los modelos como variable



$$m_{f_p \rightarrow M}(M) =$$

Inferencia eficiente


Los modelos como variable



$$m_{f_p \rightarrow M}(M) = \sum_p P(p|M) \prod_{i=1}^T P(r_i, c_i, s_i|p)$$

Inferencia eficiente


Los modelos como variable



$$m_{f_p \rightarrow M}(M) = \sum_p P(p|M) \prod_{i=1}^T P(r_i, c_i, s_i|p) = P(\text{Datos}|M)$$

Inferencia eficiente


Los modelos como variable



$$m_{f_p \rightarrow M}(M) = \sum_p P(p|M) \prod_{i=1}^T P(r_i, c_i, s_i|p) = P(\text{Datos}|M)$$

Inferencia eficiente

Los modelos como variable



$$P(M|\text{Datos}) \propto P(M, \text{Datos}) = P(\text{Datos}|M)P(M)$$

Modelos conjugados




Siglo 18: la primera solución analítica.


¿A quién le compro?

- 100% Me gusta de 10 Ratings
- 96% Me gusta de 50 Ratings
- 93% Me gusta de 200 Ratings


Siglo 18: la primera solución analítica.





Siglo 18: la primera solución analítica.



Siglo 18: la primera solución analítica.





Siglo 18: la primera solución analítica.




La cantidad total de *Me gusta*

Siglo 18: la primera solución analítica.




La cantidad total de *Me gusta*


Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.



Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)}$$

Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)} = \underbrace{(n+1)}_{1/P(k|n)} \underbrace{\frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}}_{P(k|p,n)} \underbrace{1}_{P(p)}$$

Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)} = \frac{(n+1)!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Siglo 18: la primera solución analítica.





$$P(p | k, n) = \frac{P(k | p, n) P(p)}{P(k | n)}$$

- $k=10, n=10$
- $k=48, n=50$
- $k=186, n=200$




Siglo 18: la primera solución analítica.

Aplicada en el siglo 21 para evaluar experimentos de incrementalidad




Siglo 18: la primera solución analítica.

Aplicada en el siglo 21 para evaluar experimentos de incrementalidad



Falso



Siglo 18: la primera solución analítica.


Aplicada en el siglo 21 para evaluar experimentos de incrementalidad

Con pocos datos siempre conviene usar modelos bayesianos.

Los modelos bayesianos son eficientes en datos.


Siglo 18: la primera solución analítica.

Aplicada en el siglo 21 para evaluar experimentos de incrementalidad





Siglo 18: la primera solución analítica.

Aplicada en el siglo 21 para evaluar experimentos de incrementalidad



Siglo 18: la primera solución analítica.

Aplicada en el siglo 21 para evaluar experimentos de incrementalidad



21

Modelos **22** gaussianos

23



Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

$$\int_{-\infty}^{\infty} N(x|\mu_1, \sigma_1^2) N(x|\mu_2, \sigma_2^2) dx$$

Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$

$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

$$\int_{-\infty}^{\infty} N(x|\mu_1, \sigma_1^2) N(x|\mu_2, \sigma_2^2) dx \stackrel{*}{=} \int_{-\infty}^{\infty} \underbrace{N(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2)}_{\text{constante}} \underbrace{N(x|\mu_*, \sigma_*^2) dx}_{\text{integra 1}}$$

Modelos gaussianos

Propiedades

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}(\mu|x, \sigma^2) = \mathcal{N}(-\mu|-x, \sigma^2) = \mathcal{N}(-x|-\mu, \sigma^2)$$

$$\mathcal{N}(x|\mu, \sigma^2) = \mathcal{N}\left(\frac{X - \mu}{\sigma} | 0, 1\right)$$


$$\frac{\partial}{\partial x} \Phi(x|\mu, \sigma^2) = \mathcal{N}(x|\mu, \sigma^2)$$

$$\int_{-\infty}^{\infty} N(x|\mu_1, \sigma_1^2) N(x|\mu_2, \sigma_2^2) dx \stackrel{*}{=} \int_{-\infty}^{\infty} \underbrace{N(\mu_1|\mu_2, \sigma_1^2 + \sigma_2^2)}_{\text{constante}} \underbrace{N(x|\mu_*, \sigma_*^2) dx}_{\text{integra 1}}$$

$$\mu_* = \frac{(\mu_1 \sigma_2^2 + \mu_2 \sigma_1^2)}{(\sigma_1^2 + \sigma_2^2)} \quad \sigma_* = \sqrt{\frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}}$$

Algoritmo suma-producto


Las reglas de la probabilidad por pasaje de mensajes



Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes

$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$




Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes


$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$

$$\underbrace{m_{x \rightarrow f}(x)}_{\text{Mensaje de las variables}} = \prod_{\underbrace{g \in v(x) \setminus \{f\}}_{\text{El producto de lo que recibe de atrás}}} m_{g \rightarrow x}(x)$$



Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes



$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$

$$\underbrace{m_{x \rightarrow f}(x)}_{\text{Mensaje de las variables}} = \prod_{\underbrace{g \in v(x) \setminus \{f\}}_{\text{El producto de lo que recibe de atrás}}} m_{g \rightarrow x}(x)$$

$$\underbrace{m_{f \rightarrow x}(x)}_{\text{Mensaje de los factores}} = \sum_{\mathbf{y}} \left(f(\mathbf{y}, x) \underbrace{\prod_{y \in v(f) \setminus \{x\}} m_{y \rightarrow f}(y)}_{\text{Lo que recibe de atrás por el factor, integrando todas las variables de atrás}} \right)$$


Estimación de habilidad de la industria del video juego

- Herbrich et al. **TrueSkill: A Bayesian Skill Rating System**. Advances in Neural Information Processing Systems. 2006. ([Descargar](#)). Lectura: paper completo.


Más adelante (Unidad 5.2 Modelos de historia completa):

- Dangauthier et al. *Trueskill through time: Revisiting the history of chess*. Advances in Neural Information Processing Systems. 2008. ([Descargar](#)). Lectura: paper completo.


Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego



Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b|s_b, \beta^2) \mathcal{N}(s_b|\mu_b, \sigma_b^2) ds_b$$






Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b$$




Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b$$




Estimación de habilidad en la industria del videojuego

$$\begin{aligned} p(p_b) &= \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b \\ &\stackrel{*}{=} \int \mathcal{N}(p_a | \mu_a, \beta^2 + \sigma_a^2) \mathcal{N}(s_a | \mu_*, \sigma_*^2) ds_a \end{aligned}$$




Estimación de habilidad en la industria del videojuego

$$\begin{aligned}
 p(p_b) &= \int \mathcal{N}(p_b|s_b, \beta^2) \mathcal{N}(s_b|\mu_b, \sigma_b^2) ds_b \\
 &\stackrel{*}{=} \int \underbrace{\mathcal{N}(p_b|\mu_b, \beta^2 + \sigma_b^2)}_{\text{const.}} \underbrace{\mathcal{N}(s_b|\mu_*, \sigma_*^2)}_1 ds_b
 \end{aligned}$$




Estimación de habilidad en la industria del videojuego

$$\begin{aligned} p(p_b) &= \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b \\ &\stackrel{*}{=} \mathcal{N}(p_b | \mu_b, \beta^2 + \sigma_b^2) \end{aligned}$$




Estimación de habilidad en la industria del videojuego




$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b|\mu_a, \beta^2 + \sigma_a^2)$$

Estimación de habilidad en la industria del videojuego




$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b | \mu_a, \beta^2 + \sigma_a^2)$$

Estimación de habilidad en la industria del videojuego




$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b | \mu_a, \beta^2 + \sigma_a^2)$$


Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego



Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego

$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$




Estimación de habilidad en la industria del videojuego


$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$



Estimación de habilidad en la industria del videojuego





$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$





Estimación de habilidad en la industria del videojuego

$$\hat{p}(s_b|r^*) = \arg \min_{\mu, \sigma} \text{KL}(p(s_b|r^*) || \mathcal{N}(s_b|\mu, \sigma^2))$$



Estimación de habilidad en la industria del videojuego


$$\hat{p}(s_b | r^*) = \mathcal{N}(s_b | \hat{\mu}, \hat{\sigma}^2)$$




Estimación de habilidad en la industria del videojuego

$$\underbrace{\widehat{p}(s_b | r^*)}_{\text{Posterior}_1} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2)$$

$$\widehat{\text{Posterior}}_t \rightarrow \text{Prior}_{t+1}$$



Estimación de habilidad en la industria del videojuego



$$\underbrace{\widehat{p}(s_b | r^*)}_{\text{Posterior}_1} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2)$$

$$\widehat{\text{Posterior}}_t \rightarrow \text{Prior}_{t+1}$$

$$\underbrace{p(s_b)}_{\text{Prior}_2} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2 + \gamma^2)$$

Modelos lineales

(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N} \left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2 \right)$$

Modelos lineales


(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$

Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

Función objetivo


$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$




$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

$$y = \sum_{i=0}^M w_i \cdot x^i$$

¿Cuál es el mejor modelo polinomial?

Siglo 20: Estimadores puntuales


~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato} \mid \text{hipótesis}, \text{Modelo}) P(\text{hipótesis}|\text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

¿Predecimos o “post-decimos”?

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

$$P(\text{dato}_{\text{Testear}}|\text{Modelo}) = P(\text{dato}_{\text{Testear}} \mid \arg \max_h P(\text{dato}_{\text{Entrenar}}|h, \text{Modelo}), \text{Modelo})$$



Testeo y Entrenamiento

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

Con testeo y entrenamiento





Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

Perio si empezamos a ver datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ este modelo no sirve!

Con testeo y entrenamiento



¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Y entonces el sistema de razonamiento en contextos de incertidumbre funciona mal?

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

- Y para evaluar modelos alternativos (**evidencia**),

$$P(\text{Datos}|\text{Modelos})$$

Evidencia y Posterior

Dado el prior $p(\mathbf{w})$ y el likelihood $p(\mathbf{y}|\mathbf{w})$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad p(\mathbf{y}|\mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{w} + \mathbf{b}, \mathbf{L}^{-1})$$


Obtenemos la evidencia $p(\mathbf{y})$, y el posterior $p(\mathbf{w}|\mathbf{y})$.

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^T)$$

$$p(\mathbf{w}|\mathbf{y}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\Sigma} (\mathbf{A}^T\mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}), \boldsymbol{\Sigma})$$


$$\text{con } \boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})^{-1}$$

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$




$$P(\text{Hipótesis}|\text{Datos, Modelo})$$

Priori



Espacio de datos








Verosimilitud

Priori/Posteriori

Espacio de datos

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$




Verosimilitud

Priori/Posteriori

Espacio de datos

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$



La función de costo epistémica

Todos los datos son de testeo y entrenamiento:

$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La función de costo epistémica

Todos los datos son de testeo y entrenamiento:


$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La predicción se hace con todas las hipótesis


$$P(\text{dato}_1 | \text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato}_1 | \text{hipótesis}, \text{Modelo}) P(\text{hipótesis} | \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad




$$P(\text{Modelo}|\text{Datos})$$




Evidencia

Balance natural entre complejidad y predicción




Evidencia

Balance natural entre complejidad y predicción



Evidencia



Balance natural entre complejidad y predicción



Si miramos la incertidumbre y para un $x = -0.23$, $P(y|x = -0.23)$.

Evidencia

Balance natural entre complejidad y predicción



Si miramos la incertidumbre y para un $x = -0.23$, $P(y|x = -0.23)$.

La verdadera predicción

Predicción con la contribución de todos los modelos


$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

La verdadera predicción

Predicción con la contribución de todos los modelos


$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

Si aparecen datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ van a poder ser explicados con los modelos más complejos



Altura y sexo.

Evaluación de modelos alternativos



Altura y sexo.

Evaluación de modelos alternativos


Modelo Base: $\text{altura} = h_0 + h_1 \cdot \text{altura_madre}$

Modelo Biológico: $\text{altura} = h_0 + h_1 \cdot \text{altura_madre} + h_2 \cdot \mathbb{I}(\text{sexo} = F)$

Modelo grupos al azar: $\text{altura} = h_0 \cdot \text{altura_madre} + h_{1+(\text{ID} \bmod (\max(\text{ID})/2))}$

Altura y sexo.

Evaluación de modelos alternativos



$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos

Práctica: $P(\text{Modelo Lineal}|\text{Datos})$

Evaluar modelos lineales alternativos de complejidad creciente

1. Modelos lineales de grado 0 a 9 con realidad sinoidal.
2. Modelos lineales alternativos para las alturas.