

Práctica 3 - Parte 1

Predicciones causales.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal 1
1er cuatrimestre 2026
UNSAM

Índice

1. Introducción	2
1.1. Intervenciones y experimentos	2
1.2. Variables de control backdoor	2
2. Ejercicios	4
2.1. Realidad causal: ejemplo básico.	4
2.2. Realidad causal compleja	4
2.3. Table 2 falacy	5

1. Introducción

¿Cómo estimar el efecto causal que un tratamiento $\text{do}(x)$ tiene sobre una variable objetivo y ?

$$P(y|\text{do}(x)) \quad (1)$$

1.1. Intervenciones y experimentos

Supongamos que la figura 1a representa la realidad causal subyacente con la que se generan los datos observados sin intervenciones. Allí, la elección del tratamiento X se genera naturalmente de sus causas $\{A, C, Z\}$. Intervenir una variable significa modificar el mecanismo causal asignándole un valor predeterminado,

$$P(\text{do}(X = x)) = \mathbb{I}(X = x) \quad (2)$$

lo que se representa con la distribución de probabilidad indicadora. Este mecanismo causal de las intervenciones fija un valor determinado del tratamiento independientemente de sus causas naturales. La figura 1 representa la realidad causal subyacente modificada por las intervenciones en X .




Figura 1: En rojo se encuentra la relación causal que queremos estimar.

Las consecuencias que se producen en la estructura causal cuando fijamos una variable en un valor arbitrario (Eq. 2) son las mismas que cualquier tipo de asignación aleatoria,

$$P(\text{do}(X = x)) = P(x) \quad (3)$$

pues en ambos casos la variable x se vuelve independiente del resto de las variables que no forman parte de sus descendientes. Notar que en las dos realidades causales, sea con o sin intervención, X no es independiente de Y , $Y \not\perp\!\!\!\perp X$. Esto es deseable, pues esperamos que el tratamiento tenga un efecto sobre la variable objetivo. Sin embargo, cuando fijamos el valor o lo elegimos aleatoriamente estamos eligiendo la intervención de independientemente del *resultado potencial* que obtendría la variable objetivo, $Y'|\text{do}(x')$.

$$(Y'|\text{do}(x')) \perp\!\!\!\perp X \quad (4)$$

Por este motivo, cuando la industria farmacéutica busca aprobar una nueva droga, estima el efecto causal en *experimentos aleatorios*. Para ello se seleccionan las personas al azar y se las divide en dos grupos. Un grupo recibe el tratamiento, la nueva droga, y el otro recibe un placebo, algo que aparenta ser la droga pero que se sabe que no tiene efecto alguno. Los grupos pueden ser intercambiados y el resultado observado debería ser prácticamente el mismo.

1.2. Variables de control backdoor

En esta práctica queremos estimar el efecto causal en datos observados, sin hacer experimentos aleatorios. Para poder estimar este efecto causal en base a datos observados generados sin intervención va a ser necesario encontrar un contexto Q (un conjunto de variables de control) bajo el

cual el tratamiento observado X pueda ser interpretado como si fuera un experimento aleatoria, es decir que su asignación sea independiente del *resultado potencial* que genera en la variable objetivo, $Y'|\text{do}(x')$.

$$(Y'|\text{do}(x')) \perp\!\!\!\perp X \mid \mathbf{Q} \quad (5)$$

La independencia que caracteriza a los experimentos aleatorios en la ecuación 4, y la independencia que queremos generar en base de datos sin intervenciones mediante un conjunto de variables de control $\mathbf{Q}$ en la ecuación 5, es entre el tratamiento X y el contrafactual $Y'|\text{do}(x')$.

Los contrafactuales por definición son variables no observables. Además, los contrafactuales admiten valores que son contradictorios con las observaciones factuales. Por eso los contrafactuales se modelan mediante variables *ocultas* adicionales, distintas a las variables factuales observables, compartiendo ambas las *mismas dependencias causales*. Por ejemplo, la figura 3 representa una especificación gráfica de la realidad causal subyacente original a la que se le agrega un contrafactual. Allí, el resultado potencial contrafactual $Y'|\text{do}(x')$ depende de las mismas variables $\{C, B, Z\}$ de las que depende Y y de los contrafactuales $\{W', X'\}$.




Figura 2: Modelo causal con contrafactuales.

Los modelos causales que incluyen contrafactuales se los conoce como “Twin networks”. En ellas, para que un tratamiento observado X sea independiente del resultado potencial Y' es necesario contar con conjunto de variables de control $\mathbf{Q}$ que cierre todos los flujos de inferencia entre X e Y' . Es decir, primero tenemos que listar todos los caminos que conectan a X con Y' (notar que son los mismos caminos traseros que conectan a X con Y).




Figura 3: Todos los caminos que conectan a X con Y' (también caminos traseros entre X e Y). El conjunto de variables $\mathbf{Q} = \{B, C, Z\}$ cierra el flujo de inferencia en todos los caminos.

Para que los extremos de una cadena sean independientes entre sí es necesario que haya al menos un *collider* que no forme parte del conjunto de variables de control $\mathbf{Q}$ o que haya al menos una variable no *collider* que sí forme parte del conjunto de variables de control $\mathbf{Q}$. Cuando $\mathbf{Q}$ cierra todos los caminos traseros y no contiene ninguna variable descendiente a X decimos que $\mathbf{Q}$ cumple el *backdoor criterion*.

$$P(y|\text{do}(x)) := \sum_q \underbrace{P(y|\text{do}(x), q)P(q|\text{do}(x))}_{P(y, q|\text{do}(x))}^* = \sum_q P(y|x, q)P(q) \quad (6)$$

Gracias a que Q corta solo el flujo trasero podemos estimar $P(y|\text{do}(x), q) = P(y|x, q)$. Además, gracias a que Q no contiene descendientes de X podemos estimar $P(q|\text{do}(x)) = P(q)$. Estas dos transformaciones son casos especiales de las regla 2 y 3 de *do-calculus*, que discutiremos en la siguiente sección.

Por lo tanto y para concluir esta sección teorica, presentamos la definición formal del *backdoor criterion*.

Definición 1 (*Backdoor criterion*). Un conjunto de variables Q satisface el backdoor criterion relativo a las variable Y y Z en un DAG si:

- Q cierra todos los caminos ascendentes de Z e Y (caminos no causales).
- Q no contiene ninguna variable descendente de Z a Y (caminos causales).

2. Ejercicios

Para inferir las distribuciones de probabilidad necesarias para estimar el efecto causal a partir de datos observados sin intervenciones podemos aplicar métodos no paramétricos (como un simple promedio condicional) o métodos paramétricos (como una regresión lineal, entre otros). Antes de empezar vamos a cargar algunas librerías que nos pueden resultar útiles.

```
1 import random
2 import numpy as np
3 from numpy.random import normal as noise
4 import matplotlib.pyplot as plt
5 from scipy.stats import multivariate_normal as normal
6 from scipy.stats import norm
```

Además, recomiendo cargar una librería de regresión bayesiana. En el repositorio <https://github.com/glandfried/bayesian-linear-model> se encuentra un versión completa del modelo lineal (que estima el ruido de los datos) bastante bien documentada. Solo deben clonar el repositorio y seguir las instrucciones del README.md. Cuando hagan eso, van a poder instalarla.


```
1 import linear_model as lm
2 from linear_model import BayesianLinearModel
```

Vamos a crear muestras de tamaño 5000.


```
1 N = 5000
```

2.1. Realidad causal: ejemplo básico.

Estimar el efecto causal en el siguiente modelo.



(a) Realidad causal sin intervención



(b) Realidad causal con intervención

```
1 def simular1(N=5000, do_x=None):
2     # Si hay intervencion, usar x = do_x, sino generarlo del modelo original
3     Z = np.random.uniform(-3,3, size=N)
4     if do_x is None:
```

```

5         X = 1 + 3*Z + 2*Z**3 + np.random.normal(size=N,scale=6)
6     else:
7         X = np.full(N, do_x)
8         Y = -1 - 2*X + 6*Z**2 + np.random.normal(size=N,scale=1)
9     return Z, X, Y
10
11 # Generamos los datos sin intervenciones
12 N = 5000
13 Z1s, X1s, Y1s = simular1(N)

```

Mostramos un ejemplo de cómo usar la librería `lineal_model`.


```

1 # Creamos el modelo
2 PHI1 = np.concatenate([
3     np.ones(N).reshape(N, 1),      # c_0
4     X1s.reshape(N, 1),             # c_x X
5     (Z1s**2).reshape(N, 1)],      # c_z Z^2
6 axis=1)
7
8 # Ajustamos el modelo
9 blm1= BayesianLinearModel(basis=lambda x: x)
10 blm1.update(PHI1, Y1s.reshape(N,1) )
11
12 # Obtenemos las estimaciones
13 mean1 = blm1.location
14 cov1 = blm1.dispersion
15 ev1 = blm1.evidence()

```

2.2. Realidad causal compleja

Hacer una predicción sin correlaciones espurias mediante una regresión lineal.



Para este ejercicio, se ha generado una muestra de datos sintéticos siguiendo una estructura causal compleja y no lineal. El archivo se encuentra disponible en la carpeta de datos.

```

1 # Cargar los datos
2 df_complejo = pd.read_csv('../datos/realidad_compleja.csv')
3 variables = df_complejo.columns # ['z', 'x', 'm', 'y']
4 N = len(df_complejo)

```

Utilizando el grafo provisto arriba y los datos cargados, proponga un modelo bayesiano para estimar el efecto de X sobre Y utilizando el criterio Backdoor.

Guía: Selección de variables basada en la estructura del DAG

Objetivo: Estimar consistentemente el efecto causal total de x sobre y . Basándonos en las ecuaciones generadoras, sabemos que el valor verdadero del parámetro es **-2**.

Para aplicar correctamente el Criterio Backdoor, debemos clasificar el rol de cada variable en el grafo antes de incluirla en la regresión:

- **Pipe:** Variables que se encuentran en el camino dirigido desde el tratamiento hacia la respuesta (ej. w_3 en $x \rightarrow w_3 \rightarrow y$).
- **Fork:** Variables que son ancestros comunes del tratamiento y la respuesta, generando caminos no causales.
- **Collider:** Variables donde convergen dos flechas ($\rightarrow \circ \leftarrow$).

Checklist:


- Identificaste el camino causal $x \rightarrow w_3 \rightarrow y$.
- Identificaste que POR LO MENOS hay un camino trasero.
- Probaste correr la regresión agregando w_3 y viste cómo el coeficiente de x se destruye (se vuelve incorrecto).
- Probaste correr la regresión controlando por los confusores y el coeficiente se acercó a -2.

Errores comunes:

- **Síntoma:** Agregaste absolutamente todas las variables para estar seguro.
Causa probable: Creencia de que "más datos = menos sesgo".
Arreglo: En causalidad, agregar variables incorrectas (como colliders o mediadores) crea sesgo.

2.3. Table 2 falacy

Hacer una predicción sin correlaciones espurias para el flujo de inferencia entre S e Y .



Cargue el siguiente dataset:

```
1 df_falacia = pd.read_csv('../datos/falacia_tabla2.csv')
```

Interpretar los coeficientes de una regresión múltiple como efectos causales independientes es un error común conocido como la "Falacia de la Tabla 2".

Guía: ¿Qué es la Falacia de la Tabla 2?

Muchas veces, cuando corremos una regresión del tipo:

$$Y \sim \beta_1 \text{Tratamiento} + \beta_2 \text{Covariable A} + \beta_3 \text{Covariable B}$$

Pensamos que β_1 es el efecto del tratamiento, β_2 es el efecto de A, y β_3 el de B. **¡Esto es mentira!**

Un modelo causal se ajusta para estimar **un solo** efecto (el de tu variable de interés).

- Si diseñaste el modelo para estimar el efecto de S , entonces β_S es causalmente válido.
- Pero los coeficientes de E y F (que usaste solo de control) quedan rotos causalmente: absorben partes de efectos que no les corresponden para limpiar a S .

Conclusión: Si querés saber el efecto de E , ¡tenés que armar otro DAG y correr otro modelo pensado para E !

Checklist:

- Corriste la regresión para estimar el efecto de S .
- Verificaste que el coeficiente de S se parece al verdadero (definido en el código).
- Miraste los coeficientes de E y F en esa misma tabla y notaste que **no** coinciden con sus efectos causales reales (simulados en el código).

Errores comunes:

- **Síntoma:** Presentar una tabla de regresión y decir "La variable S aumenta Y en 2 puntos, y la variable F lo aumenta en 3 puntos...".
Causa probable: Interpretar coeficientes de control como efectos causales totales.
Arreglo: Interpretá solo el coeficiente de tu variable de tratamiento. Para los otros, decí controlando por...