

Estimandos, do-calculus

Unidad 3.2




Estimandos, do-calculus

Unidad 3.2

El estimando del efecto causal general: adjustment formula y propensity score. La característica fundamental de los experimentos aleatorizados: independencia entre el tratamiento y sus resultados potenciales contrafactuales. La analogía “ignorabilidad condicional” como criterio para seleccionar variables de control en el enfoque previo de inferencia causal basado en resultados potenciales contrafactuales. Estimando del efectos causales bajo ignorabilidad condicional y consistencia determinista. Las 3 reglas del Do-calculus: Regla 1, Ignorar una observación; Regla 2, Intervención como observación; Regla 3. Ignorar una intervención. Estimando alternativo en casos de que haya controles ocultos: frontdoor formula. Estimando alternativo cuando fallan los experimentos aleatorios: instrumental variables.

Estimación de efecto causal


Modelo causal intervenido (M_T)



Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$




Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t)$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0, t, e_1)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) P_{M_T}(t) P_{M_T}(e_1|t, e_0)}{P_{M_T}(t)}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P_{M_T}(e_0) P_{M_T}(e_1|t, e_0) \end{aligned}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$




$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

Distribuciones
observadas!

Estimación de efecto causal

Modelo causal intervenido (M_T)

$$\begin{aligned} P_{M_T}(T) &= \text{Bern}(0.5) \\ P_{M_T}(E_0) &= P(E_0) \\ P_{M_T}(E_1|T, E_0) &= P(E_1|T, E_0) \end{aligned}$$


```
graph LR; E0 --> E1; T --> E1;
```

$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

Distribuciones observadas! • Encontramos los efectos causales en cada subgrupo $P(e_1|t, e_0)$
• Y los ponderamos por el tamaño de cada subgrupo $P(e_0)$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}_{\text{Efecto causal general}}$$


Estimación de efecto causal

Modelo causal intervenido (M_T)

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}_{\text{Efecto causal general}} = -0.0646$$

Los 4 pasos de la estimación de efecto causales

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal

Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales


Especificar la estructura causal subyacente

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales

Definir el estimando (variables de control y modelo)

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. Computar las estimaciones de impacto causal
4. Validar los resultados

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

Siempre podemos evaluar modelos alternativos en base a la evidencia

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

Pero acá conocemos la función.

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\mathbb{E}[y|m] = -1 + 2m^2$$

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\mathbb{E}[y|m] = -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2$$

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\mathbb{E}[y|m] = -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2$$

$$= -1 + 200x^2 + 80xz^2 + 8z^4 = \mathbb{E}[y|x, z]$$

Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$y \sim x^2 + xz^2 + z^4$$

Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. Computar las estimaciones de impacto causal
4. Validar los resultados


Los 4 pasos de la estimación de efecto causales

Computar las estimaciones de impacto causal

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. Validar los resultados


Los 4 pasos de la estimación de efecto causales

Computar las estimaciones de impacto causal



Los 4 pasos de la estimación de efecto causales

Computar las estimaciones de impacto causal



Los 4 pasos de la estimación de efecto causales

Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**

Los 4 pasos de la estimación de efecto causales

Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z)$$

Los 4 pasos de la estimación de efecto causales

Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z)$$

pero todavía no estimamos el efecto causal general

$$P(y|\text{do}(x)) = P_{M_x}(y|x)$$


Los 4 pasos de la estimación de efecto causales

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$




Los 4 pasos de la estimación de efecto causales

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(\text{do}(x)) = \mathbb{I}(X = x)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$¿ \quad P(y|\text{do}(x)) = P_{M_x}(y|x) \quad ?$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$P(Y = y | \text{do}(X = x)) = P_{M_x}(Y = y | X = x)$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y|\text{do}(X = x)) &= P_{M_x}(Y = y|X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q|X = x)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) P(Y = y | X = x, Q = q)\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables $\mathbf{Q}$ cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&= \sum_q^* \underbrace{P(Q = q)}_{\text{Peso de } q} \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

Estimador del efecto causal general

Adjustment formula

Demostración

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos.

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X).

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q, W, X, Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q)P(W, X, Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, X, Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \underbrace{\sum_{W, X, Y} P(W, X, Y|Q)}_1$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, Y|Q)P(X|Q, W, Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \sum_X P(X|Q,W,Y)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \underbrace{\sum_X P(X|Q,W,Y)}_1$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q)$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$

Estimador del efecto causal general

Adjustment formula

Demostración

Parte 1. $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque X no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque Q corta el flujo trasero.

Parte 2. $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) = P(Q = q)$

2.a En el lado izquierdo X no recibe flechas, se conecta con Q solo por caminos con collider ocultos. Luego, $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de X). Sea W el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$

Estimador del efecto causal general

Adjustment formula

Adjustment formula

Si un conjunto de variables Q cumple con el criterio *backdoor* de X a Y , entonces el efecto causal de X en Y es estimable (identificable) a través de la siguiente fórmula:

$$\underbrace{P(y|\text{do}(x)) = P_{M_x}(y|x)}_{\text{Realidad intervenida}} = \sum_q \underbrace{\overbrace{P(q)}^{\text{Peso del efecto}} \overbrace{P(y|x, q)}^{\text{Efecto heterogéneo}}}_{\text{Realidad sin intervenir}}$$


Estimación de efecto causal general

Modelo polinomial

```
def p_Y_doX(y,x):  
    res = 0  
    for z in z_grilla:  
        pz = normal(0,1).pdf(z)  
        mu_y_xz = regression(y,x,z)  
        py_xz = norm(loc=mu_y_xz, scale=sigma).pdf(y)  
        res += (pz*py_xz)*dz  
    return res
```

Estimación de efecto causal general

Modelo polinomial



Inferencia pasiva de efecto causal

Casos especiales y criterio general.


Casos especiales

La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables




Casos especiales

La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables



No podemos eliminar la asociación espuria entre F y C !

Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Ajuste frontdoor.

Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Ajuste frontdoor.

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f))$$

Casos especiales


La disputa contra la industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Ajuste frontdoor.

Condición: hay una sola variable mediadora.

Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



No podemos eliminar la asociación espuria entre T e Y !

Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

$$\mathbb{E}[y|\text{do}(a)] = \alpha \beta a$$

Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

$$\mathbb{E}[y|\text{do}(a)] = \alpha \beta a$$

$$\mathbb{E}[y|\text{do}(t)] = \mathbb{E}[y|\text{do}(a)] / \mathbb{E}[t|\text{do}(a)]$$

Casos especiales


Experimentos imperfectos

A : Asignación aleatoria

T : Tratamiento

U : Otras variables

Y : Objetivo



Instrumental variable


Condición: T es la única variable mediadora.

El ecosistema causal de Python

DoWhy, EconML, PyTorch y más

Causal Inference and Discovery in Python

Unlock the secrets of modern causal machine learning
with DoWhy, EconML, PyTorch and more



ALEKSANDER MOLAK


Casos especiales

La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables



Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$D = 0$		$D = 1$			
	$F = 0$	$F = 1$	$F = 0$	$F = 1$	$F = 0$	$F = 1$
$C = 0$	10% 38/380	90% 18/20	5% 1/20	85% 323/380	9.75% 39/400	85% 341/400
$C = 1$	90% 342/380	10% 2/20	95% 19/20	15% 57/380	90.25% 361/400	15% 59/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$D = 0$		$D = 1$			
	$F = 0$	$F = 1$	$F = 0$	$F = 1$	$F = 0$	$F = 1$
$C = 0$	10% 38/380	90% 18/20	5% 1/20	85% 323/380	9.75% 39/400	85% 341/400
$C = 1$	90% 342/380	10% 2/20	95% 19/20	15% 57/380	90.25% 361/400	15% 59/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$		
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	380/400	20/400
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$		

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	20/400	380/400

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

	$F = 0$		$F = 1$			
	$D = 0$	$D = 1$	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	10% 38/380	5% 1/20	90% 18/20	85% 323/380	19% 56/400	81% 324/400
$C = 1$	90% 342/380	95% 19/20	10% 2/20	15% 57/380	81% 344/400	9% 76/400

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

¿Podemos evaluar el efecto causal de F en C
sin controlar por U ?

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$P(d|\text{do}(f)) = ?$ (se puede controlar?)

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = ?$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

Casos especiales


La disputa contra el industria del tabaco

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f) P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = ?$$

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$

$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f))$$

Casos especiales

La disputa contra el industria del tabaco


$F = 0$	$F = 1$
0.5	0.5

F : Fumar

C : Cancer

U : Otras variables

D : Depósitos en pulmones



$P(d f)$	$D = 0$	$D = 1$
$F = 0$	0.95	0.05
$F = 1$	0.05	0.95

$$P(d|\text{do}(f)) = P(d|f)$$


$$P(c|\text{do}(d)) = \sum_f P(c|d, f)P(f)$$

$P(c d, f)$	$F = 0$		$F = 1$	
	$D = 0$	$D = 1$	$D = 0$	$D = 1$
$C = 0$	0.1 38/380	0.05 1/20	0.9 18/20	0.85 323/380
$C = 1$	0.9 342/380	0.95 19/20	0.1 2/20	0.15 57/380

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f)) = \sum_d P(d|f) \sum_{f'} P(c|d, f')P(f')$$

Frontdoor criterion


Doble aplicación de backdoor



$$P(y|\text{do}(t)) = \sum_m P(m|t) \sum_{t'} P(y|m, t') P(t')$$

Frontdoor criterion

Doble aplicación de backdoor



$$P(y|\text{do}(t)) = \sum_m P(m|t) \sum_{t'} P(y|m, t') P(t')$$


Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T

¿Frontdoor criterion?

Doble aplicación de backdoor




Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T

Frontdoor criterion

Doble aplicación de backdoor




Frontdoor criterion

Un conjunto de variables mediadoras M satisfacen el criterio *frontdoor* entre un tratamiento T y una variable objetivo Y si:

1. M media completamente el efecto causal de T en Y
2. No hay caminos traseros abiertos entre M y T
3. Todos los caminos traseros entre M e Y están bloqueados por T


Criterio propio

Doble aplicación de backdoor



Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) =$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = ? \text{ (hay controles?)}$$

Criterio propio


Doble aplicación de backdoor



$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = ?$$

Criterio propio

Doble aplicación de backdoor




$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = \sum_{t, w_1, w_2} P(y|m, t, w_1, w_2)P(t, w_1, w_2)$$

Criterio propio

Doble aplicación de backdoor

$$P(y|\text{do}(t)) = \sum_m P(y|\text{do}(m))P(m|\text{do}(t))$$



$$P(m|\text{do}(t)) = \sum_{w_1} P(m|t, w_1)P(w_1)$$

$$P(y|\text{do}(m)) = \sum_{t, w_1, w_2} P(y|m, t, w_1, w_2)P(t, w_1, w_2)$$

do-calculus

Criterio general

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos $\mathbf{T}$ y los objetivos $\mathbf{Y}$ dadas las co-variables $\mathbf{Q}$ (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{z}), \text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\text{do}(\mathbf{z}), \mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}, \mathbf{X}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x})) = P(\mathbf{c}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}}}} \mathbf{X} \quad (\text{controles } \mathbf{c})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(\mathbf{V})}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$

Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{z}), \text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\text{do}(\mathbf{z}), \mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{Z}}, \overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Criterio general

Determina el estimador de un efecto causal entre los tratamientos T y los objetivos Y dadas las co-variables Q (siempre que sea identificable).

$$P(\mathbf{y}|\text{do}(\mathbf{t}), \mathbf{q})$$

Regla 1 (Ignorar una observación):

$$P(\mathbf{v}|\mathbf{x}, \mathbf{c}) = P(\mathbf{v}|\mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_G \mathbf{X} \mid \mathbf{C} \quad (\text{d-separación})$$

Regla 2 (Intervención como observación):

$$P(\mathbf{v}|\text{do}(\mathbf{x}), \mathbf{c}) = P(\mathbf{v}|\mathbf{x}, \mathbf{c}) \quad \text{si} \quad \mathbf{V} \perp\!\!\!\perp_{G_{\underline{\mathbf{X}}}} \mathbf{X} \mid \mathbf{C} \quad (\text{no backdoor})$$


Regla 3 (Ignorar una intervención):

$$P(\mathbf{c}|\text{do}(\mathbf{x}), \mathbf{v}) = P(\mathbf{c}|\mathbf{v}) \quad \text{si} \quad \mathbf{C} \perp\!\!\!\perp_{G_{\overline{\mathbf{X}(V)}}} \mathbf{X} \mid \mathbf{V} \quad (\text{controles } \mathbf{c})$$

Seguro vale para intervenciones que no son ancestros de V , $X(V)$, porque V puede ser collider

do-calculus

Regla 3. Ignorar una intervención.




$$P(q|\text{do}(t)) = P(q)$$

Si q son variables ascendentes a t ,
 q no se ve afectado por la intervención en t

do-calculus

Regla 3. Ignorar una intervención.




$$P(q|\text{do}(t), y) \neq P(q|y)$$

Si q son variables ascendentes a t ,
 q no se ve afectado por la intervención en t

salvo que algún collider abra el flujo de inferencia

do-calculus


Derivando frontdoor y backdoor



do-calculus

Derivando frontdoor y backdoor


$$P(y|\text{do}(t)) = \sum_m P(y, m|\text{do}(t))$$



do-calculus

Derivando frontdoor y backdoor


$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t))\end{aligned}$$




do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t)) \end{aligned}$$




$$P(m|\text{do}(t)) =$$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t))\end{aligned}$$



$$P(m|\text{do}(t)) =$$


Intervención como observación
no backdoor entre t y m



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|\text{do}(t)) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

Intervención como observación
no backdoor entre t y m




do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m) \textcolor{red}{P}(m|t)\end{aligned}$$

$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$





do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$

$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) =$$



do-calculus

Derivando frontdoor y backdoor


$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m))$$


Intervención como observación
No hay backdoor entre m e y dado $\text{do}(t)$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) =$$



do-calculus

Derivando frontdoor y backdoor



$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m))$$


Ignorar una intervención
No hay controles descendentes a t



do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$




$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y, t'|\text{do}(m))$$

do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$




$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y|\text{do}(m), t')P(t'|\text{do}(m))$$

do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) = \sum_{t'} P(y|\text{do}(m), t') \textcolor{red}{P(t'|\text{do}(m))}$$



do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|\text{do}(m), t') P(t')$$




Ignorar una intervención
Intervenir en m no afecta a t

do-calculus


Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$


$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|\text{do}(m), t')P(t')$$



do-calculus

Derivando frontdoor y backdoor



$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(y|\text{do}(t), m)P(m|t) \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t')P(t')$$


Intervención como observación
No hay backdoor entre m e y dado t



do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned}P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\&= \sum_m P(y|\text{do}(t), m)P(m|t)\end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t')P(t')$$


Derivamos:

- Dos casos especiales de backdoor, $P(m|\text{do}(t))$ y $P(y|\text{do}(m))$.
- Y un caso especial de frontdoor, $P(y|\text{do}(t))$.

do-calculus

Derivando frontdoor y backdoor

$$\begin{aligned} P(y|\text{do}(t)) &= \sum_m P(y, m|\text{do}(t)) \\ &= \sum_m P(m|t) \sum_{t'} P(y|m, t') P(t') \end{aligned}$$



$$P(m|\text{do}(t)) \stackrel{2}{=} P(m|t)$$

$$P(y|\text{do}(t), m) \stackrel{2}{=} P(y|\text{do}(t), \text{do}(m)) \stackrel{3}{=} P(y|\text{do}(m)) \stackrel{3}{=} \sum_{t'} P(y|m, t') P(t')$$

Inverse Probability Weighting

$$P(y|\text{do}(x)) = \sum_{\kappa} P(y|x, \kappa)P(\kappa)$$

Inverse Probability Weighting

$$P(y|\text{do}(x)) = \left(\frac{P(x|\kappa)}{P(x)} \right) \sum_{\kappa} P(y|x, \kappa) P(\kappa)$$

Inverse Probability Weighting

$$P(y|\text{do}(x)) = \sum_{\kappa} \frac{P(y|x, \kappa)P(x|\kappa)P(\kappa)}{P(x|\kappa)}$$

Inverse Probability Weighting

$$P(y|\text{do}(x)) = \sum_{\kappa} \frac{P(y|x, \kappa)P(x|\kappa)P(\kappa)}{P(x|\kappa)} = \sum_{\kappa} \frac{P(y, x, \kappa)}{P(x|\kappa)}$$

Inverse Probability Weighting

$$P(y|\text{do}(x)) = \sum_{\kappa} \frac{P(y|x, \kappa)P(x|\kappa)P(\kappa)}{P(x|\kappa)} = \sum_{\kappa} \frac{P(y, x, \kappa)}{P(x|\kappa)}$$

Propensity Score $:= P(x|\kappa)$

(Se usa cuando la combinación de valores de κ es algunos órdenes de magnitud mayor a el tamaño de la muestra.)


Inverse Probability Weighting

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$


	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	0.15
$T = 1$	0.90	0.10
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	0.30
$T = 1$	0.80	0.20


Inverse Probability Weighting



	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600


Inverse Probability Weighting

	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



Inverse Probability Weighting


	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

Inverse Probability Weighting


	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$	t	e_0	e_1	$P(e_0, e_1 t = 1)$
1	1	1	0.0488	1	1	1	$0.0488/P(t = 1)$
1	1	0	0.1951	1	1	0	$0.1951/P(t = 1)$
1	0	1	0.0024	1	0	1	$0.0024/P(t = 1)$
1	0	0	0.0220	1	0	0	$0.0220/P(t = 1)$
0	1	1	0.0146				
0	1	0	0.0341				
0	0	1	0.1024				
0	0	0	0.5805				
			1.0000				

Inverse Probability Weighting


	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$	t	e_0	e_1	$P(e_0, e_1 t = 1)$
1	1	1	0.0488	1	1	1	$0.0488/P(t = 1)$
1	1	0	0.1951	1	1	0	$0.1951/P(t = 1)$
1	0	1	0.0024	1	0	1	$0.0024/P(t = 1)$
1	0	0	0.0220	1	0	0	$0.0220/P(t = 1)$
0	1	1	0.0146				
0	1	0	0.0341				
0	0	1	0.1024				
0	0	0	0.5805				
			1.0000				
			1.0000				

Inverse Probability Weighting

	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333




t	e_0	e_1	$P(t, e_0, e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0, e_1 t = 1)$
1	1	1	$0.0488/P(t = 1)$
1	1	0	$0.1951/P(t = 1)$
1	0	1	$0.0024/P(t = 1)$
1	0	0	$0.0220/P(t = 1)$
			1.0000

t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	$0.0488/P(t e_0)$
1	1	0	$0.1951/P(t e_0)$
1	0	1	$0.0024/P(t e_0)$
1	0	0	$0.0220/P(t e_0)$
			1.0000

Inverse Probability Weighting

	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333




t	e_0	e_1	$P(t, e_0, e_1)$	t	e_0	e_1	$P(e_0, e_1 t = 1)$	t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	0.0488	1	1	1	$0.0488/P(t = 1)$	1	1	1	$0.0488/P(t e_0)$
1	1	0	0.1951	1	1	0	$0.1951/P(t = 1)$	1	1	0	$0.1951/P(t e_0)$
1	0	1	0.0024	1	0	1	$0.0024/P(t = 1)$	1	0	1	$0.0024/P(t e_0)$
1	0	0	0.0220	1	0	0	$0.0220/P(t = 1)$	1	0	0	$0.0220/P(t e_0)$
0	1	1	0.0146				1.0000				1.0000
0	1	0	0.0341								
0	0	1	0.1024								
0	0	0	0.5805								
			1.0000								

$$P(t = 1) = \sum_t P(t, e_0, e_1) = \mathbf{0.2683}$$

Inverse Probability Weighting


	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$	t	e_0	e_1	$P(e_0, e_1 t = 1)$	t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	0.0488	1	1	1	0.1818	1	1	1	$0.0488/P(t e_0)$
1	1	0	0.1951	1	1	0	0.7272	1	1	0	$0.1951/P(t e_0)$
1	0	1	0.0024	1	0	1	0.0909	1	0	1	$0.0024/P(t e_0)$
1	0	0	0.0220	1	0	0	0.0818	1	0	0	$0.0220/P(t e_0)$
0	1	1	0.0146				1.0000				1.0000
0	1	0	0.0341								
0	0	1	0.1024								
0	0	0	0.5805								
			1.0000								

Inverse Probability Weighting

	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333




t	e_0	e_1	$P(t, e_0, e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0, e_1 t = 1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	$0.0488/P(t e_0)$
1	1	0	$0.1951/P(t e_0)$
1	0	1	$0.0024/P(t e_0)$
1	0	0	$0.0220/P(t e_0)$
			1.0000

Inverse Probability Weighting


	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$	t	e_0	e_1	$P(e_0, e_1 t = 1)$	t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	0.0488	1	1	1	0.1818	1	1	1	0.0488/0.8333
1	1	0	0.1951	1	1	0	0.7272	1	1	0	0.1951/0.8333
1	0	1	0.0024	1	0	1	0.0909	1	0	1	0.0024/0.0345
1	0	0	0.0220	1	0	0	0.0818	1	0	0	0.0220/0.0345
0	1	1	0.0146				1.0000				1.0000
0	1	0	0.0341								
0	0	1	0.1024								
0	0	0	0.5805								
			1.0000								

Inverse Probability Weighting

	$P(T E_0)$	
	$T = 0$	$T = 1$
$E_0 = 0$	0.9655	0.0345
$E_0 = 1$	0.1666	0.8333



t	e_0	e_1	$P(t, e_0, e_1)$
1	1	1	0.0488
1	1	0	0.1951
1	0	1	0.0024
1	0	0	0.0220
0	1	1	0.0146
0	1	0	0.0341
0	0	1	0.1024
0	0	0	0.5805
			1.0000

t	e_0	e_1	$P(e_0, e_1 t = 1)$
1	1	1	0.1818
1	1	0	0.7272
1	0	1	0.0909
1	0	0	0.0818
			1.0000

t	e_0	e_1	$P(e_0, e_1 \text{do}(t = 1))$
1	1	1	0.0585
1	1	0	0.2341
1	0	1	0.0707
1	0	0	0.6366
			1.0000

$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos